



Universidad Internacional de La Rioja
Facultad de Empresa, Comunicación y Marketing

Máster Universitario en Inteligencia de Negocio

Desde el Dato hasta la Decisión: Un
Sistema Integral de BI para Altadis

Trabajo fin de estudio presentado por:	Miguel Casares Moreno, Adrián Gallardo Muñoz y María Belén Flores Cofre
Tipo de trabajo:	Proyecto de Inteligencia de Negocio
Modalidad:	Grupal
Director/a:	
Fecha:	16/07/2025

Organización de trabajo en equipo y mecanismos de coordinación

Dado que este Trabajo de Fin de Máster se ha desarrollado en modalidad grupal, ha sido fundamental establecer una organización clara del trabajo y unos mecanismos de coordinación eficaces para asegurar la coherencia, calidad y profundidad del análisis realizado. El equipo ha estado conformado por tres integrantes: Miguel Casares Moreno, Adrián Gallardo Muñoz y Belén Flores Cofré, quienes han colaborado de manera activa y estructurada durante todas las fases del proyecto.

Desde el inicio, se acordó una división inicial de tareas basada en áreas específicas de análisis, atendiendo tanto a las preferencias personales como a la experiencia previa de cada integrante. Miguel Casares asumió la responsabilidad del análisis de ventas, Adrián se centró en el módulo de entregas, y Belén trabajó en la parte relativa a rutas de distribución y roturas de stock. Esta segmentación permitió profundizar en cada dimensión del negocio de forma especializada, sin perder de vista la visión conjunta del proyecto.

Para garantizar una base común de datos coherente y limpia, se programó una primera fase conjunta de integración y preparación de datos utilizando R Studio. En esta etapa, el grupo se reunió de forma virtual, coordinándose para consolidar las distintas fuentes de información y construir las cuatro tablas de hechos principales del sistema de inteligencia de negocio. Este trabajo colaborativo permitió resolver de forma ágil inconsistencias y asegurar que todas las dimensiones estuvieran correctamente alineadas.

Una vez completada esta fase, cada miembro del equipo procedió al análisis exhaustivo de su bloque temático y al desarrollo de dashboards individuales en Power BI, incluyendo KPIs relevantes, segmentaciones y propuestas de mejora. Durante esta fase, se mantuvieron reuniones semanales para compartir avances, recibir feedback mutuo y alinear criterios de visualización y storytelling, lo que favoreció la coherencia global del sistema final.

Además de las sesiones grupales periódicas, se utilizaron herramientas de trabajo colaborativo como Google Drive para el intercambio de documentación, GitHub para control de versiones del código en R, y Microsoft Teams como canal de comunicación principal. Estas herramientas facilitaron un flujo de trabajo ágil, permitiendo resolver incidencias técnicas y organizativas en tiempo real.

En las fases finales del proyecto, el equipo volvió a trabajar de forma conjunta para integrar los distintos dashboards en un informe unificado, revisar la consistencia del modelo de datos, validar los resultados obtenidos y preparar la presentación del TFM. Esta organización, que combinó especialización individual con revisión colectiva, ha sido clave para alcanzar los objetivos planteados y garantizar la calidad técnica y analítica del trabajo realizado.

Resumen

Este Trabajo de Fin de Máster presenta un sistema integral de inteligencia de negocio diseñado para la compañía Altadis, con el objetivo de optimizar su red de distribución y toma de decisiones basada en datos. Utilizando R para la limpieza y consolidación de datos, se han generado cuatro tablas de hechos clave que permiten un análisis profundo de ventas, entregas, rutas y estancos. Posteriormente, se construye un modelo de Data Warehouse y se visualizan KPIs relevantes mediante dashboards en Power BI. El sistema incluye análisis de calidad de datos, modelado predictivo para ventas y out-of-stock, y segmentación de clientes mediante clustering, aportando insights de gran valor estratégico.

Abstract

This Master's Thesis presents a comprehensive business intelligence system designed for Altadis, aimed at optimizing its distribution network and data-driven decision-making. Using R for data cleaning and consolidation, four key fact tables have been created to support deep analysis of sales, deliveries, routes, and retailers. A Data Warehouse model was constructed and key performance indicators were visualized through Power BI dashboards. The system includes data quality analysis, predictive modeling for sales and out-of-stock events, and customer segmentation via clustering, delivering valuable strategic insights.

Índice de contenidos

Contenido

Organización de trabajo en equipo y mecanismos de coordinación.....	2
1. Introducción.....	13
1.1. Planteamiento general: descripción y justificación del proyecto.....	13
1.2. Objetivos del TFE.....	13
1- Integrar, limpiar y estructurar los datos operativos de Altadis.....	13
2- Diseñar un modelo de Data Warehouse basado en 4 tablas de hechos.....	13
3- Implementar un sistema de visualización en Power BI con KPIs estratégicos.....	13
4- Aplicar modelos de clustering para segmentar puntos de venta.....	13
5- Desarrollar modelos predictivos para ventas y roturas de stock.....	13
1.3. Elementos innovadores del proyecto.....	14
1- Integración de fuentes heterogéneas (estancos, ventas, rutas, vending).....	14
2- Modelado multidimensional adaptado al contexto regulado del tabaco.....	14
3- Visualizaciones interactivas para directivos no técnicos.....	14
4- Incorporación de variables geográficas y temporales externas.....	14
2. Alcance y planificación.....	15
2.1. Fase de descubrimiento: evaluación del entorno actual.....	15
1- Información deseada.....	15
2- Información actual: deficiencias y soluciones alternativas.....	15
3- Habilidades analíticas actuales.....	15
2.2. Fase de análisis: identificación de <i>gaps</i>	16
1- Capacidad de los informes actuales.....	16
2- Proveedores de tecnología necesarias.....	16
3- Diferencia entre los informes actuales y la información deseada.....	16
4- Cronología, costes y recursos humanos implicados.....	17
2.3. Fase de recomendaciones: alcance, prioridades y presupuesto.....	18
1- Promoción del proyecto en la organización.....	18
2- Demostraciones.....	18
3. Análisis y definición.....	20
3.1. Análisis de los datos a utilizar.....	20
1- Tabla de hechos: VENTAS.....	20
2- “Tabla de hechos: ENVIOS.....	21
3- Tabla de hechos: RUTA.....	21

4-	Tabla de hechos: ROTURAS DE STOCK	22
3.2.	Análisis histórico y/o limpieza de datos	23
1-	Tabla de hechos: VENTAS	23
2-	Tabla de hechos: ENVIOS	24
3-	Tabla de hechos: RUTA	26
4-	Tabla de hechos: ROTURA DE STOCK.....	30
3.3.	Modelado propuesto	35
1-	Tabla de hechos: VENTAS	35
2-	Tabla de hechos: ENVIOS	39
3-	Tabla de hechos: RUTA	43
4-	Tabla de hechos: ROTURA DE STOCK.....	54
4.	Construcción, prueba, implementación y despliegue	70
4.1.	Medidas de bondad del modelado	70
1-	Tabla de hechos: VENTAS	70
2-	Tabla de hechos: ENVIOS	70
3-	Tabla de hechos: RUTA	70
4-	Tabla de hechos: ROTURA DE STOCK.....	70
5-	Validación de modelos	71
4.2.	Ejemplo de aplicación.....	71
1-	Tabla de hechos: VENTAS	71
2-	Tabla de hechos: ENVIOS	72
3-	Tabla de hechos: RUTA	72
4-	Tabla de hechos: ROTURA DE STOCK.....	73
5.	Cronograma del proyecto	74
5.1.	Swimlane de Inteligencia de negocio	74
5.2.	Swimlane de datos y bases de datos	74
5.3.	Swimlane de la integración de datos	74
5.4.	Swimlane de la infraestructura	74
5.5.	Swimlane de la gestión del proyecto.....	75
6.	Conclusiones	76
6.1.	Conclusiones por tipo de Análisis	76
1-	Tabla de hechos: VENTAS	76
2-	Tabla de Hechos: ENVÍO	77
3-	Tabla de Hechos: RUTA.....	77
4-	Tabla de Hechos: Rotura de Stock.....	78
5-	Impacto organizacional de la transformación digital propuesta:	79
7.	Limitaciones y prospectiva	79

7.1.	Limitaciones de datos.....	79
1-	Datos facilitados.....	80
2-	Clustering.....	80
3-	Aplicaciones para el análisis y visualización	80
4-	Información escasa	81
7.2.	Prospectiva.....	81
8.	Referencias bibliográficas	83
ANEXO I: Cuadros de Mando		84

Índice de figuras

Figura1.....	24
Figura2.....	25
Figura3.....	28
Figura4.....	28
Figura5.....	29
Figura6.....	30
Figura7.....	30
Figura8.....	31
Figura9.....	31
Figura10.....	32
Figura11.....	33
Figura12.....	34
Figura13.....	35
Figura14.....	37
Figura15.....	38
Figura16.....	38
Figura17.....	41
Figura18.....	43
Figura19.....	44
Figura20.....	45
Figura21.....	46
Figura22.....	40
Figura23.....	40
Figura24.....	40

Figura25.....	40
Figura26.....	40
Figura27.....	40
Figura28.....	40
Figura29.....	40
Figura30.....	40
Figura31.....	40
Figura32.....	40
Figura33.....	40
Figura34.....	40
Figura35.....	40
Figura36.....	40
Figura37.....	40
Figura38.....	40
Figura39.....	40
Figura41.....	40
Figura42.....	40
Figura42.....	40
Figura43.....	40
Figura44.....	40

Índice de tablas

Tabla 1.....	44
Tabla 2.....	45
Tabla 3.....	46
Tabla 4.....	48
Tabla 5.....	49
Tabla 6.....	55
Tabla 7.....	56
Tabla 8.....	57
Tabla 9.....	58
Tabla 10.....	59
Tabla 11.....	61

1. Introducción

En este apartado procederemos a poner en contexto la empresa Altadis. Explicaremos en que sector trabaja y como es su funcionamiento empresarial. Además, expondremos como se va a trabajar con los datos proporcionados por la Universidad Internacional de la Rioja y que etapas se seguirán para lograr los objetivos propuestos y ofrecer una visión global de dicha empresa.

1.1.Planteamiento general: descripción y justificación del proyecto

Altadis, parte del grupo Imperial Brands, opera en el sector de productos de tabaco y dispositivos de nueva generación, distribuyendo sus productos a través de una red de estancos y puntos de venta con recargo. El presente proyecto responde al reto propuesto por la empresa, que busca un sistema de Business Intelligence que permita consolidar y analizar grandes volúmenes de datos generados en su proceso logístico-comercial, con el fin de facilitar la toma de decisiones. La creciente complejidad del entorno comercial y la diversidad de canales requieren una plataforma ágil, intuitiva y robusta.

1.2.Objetivos del TFE

- 1- Integrar, limpiar y estructurar los datos operativos de Altadis.
- 2- Diseñar un modelo de Data Warehouse basado en 4 tablas de hechos.
- 3- Implementar un sistema de visualización en Power BI con KPIs estratégicos.
- 4- Aplicar modelos de clustering para segmentar puntos de venta.
- 5- Desarrollar modelos predictivos para ventas y roturas de stock.

1.3.Elementos innovadores del proyecto

- 1- Integración de fuentes heterogéneas (estancos, ventas, rutas, vending).
- 2- Modelado multidimensional adaptado al contexto regulado del tabaco.
- 3- Visualizaciones interactivas para directivos no técnicos.
- 4- Incorporación de variables geográficas y temporales externas.

2. Alcance y planificación

2.1. Fase de descubrimiento: evaluación del entorno actual

1- Información deseada

- 2.1.1.1. Comportamiento de ventas por canal y zona.
- 2.1.1.2. Análisis de cobertura y eficiencia de las rutas
- 2.1.1.3. Frecuencia y patrones de rotura de stock.

2- Información actual: deficiencias y soluciones alternativas.

Los datos proporcionados estaban divididos en seis ficheros CSV, anonimizados y no integrados. Se detectaron problemas de duplicados, formatos inconsistentes y ausencias.

3- Habilidades analíticas actuales.

El equipo de trabajo cuenta con una base sólida en análisis de datos, adquirida durante el desarrollo del Máster, lo que ha permitido abordar con solvencia las distintas fases del proyecto. En particular, se dispone de competencias en limpieza, transformación y modelado de datos mediante herramientas como R, lo que ha resultado fundamental para integrar fuentes heterogéneas, detectar inconsistencias y preparar la información para su análisis.

Asimismo, se ha desarrollado experiencia en la construcción de modelos de datos estructurados utilizando principios de Data Warehousing, así como en la aplicación de técnicas estadísticas básicas y modelos de análisis predictivo (regresión, clustering, detección de outliers, etc.).

En el ámbito de la visualización y la comunicación de resultados, el equipo ha trabajado ampliamente con Power BI, aprovechando sus capacidades para el diseño de dashboards interactivos, definición de KPIs relevantes y creación de informes dinámicos orientados a la toma de decisiones empresariales.

Estas habilidades, complementadas con un enfoque colaborativo y metodologías de trabajo ágil, han permitido implementar una solución de inteligencia de negocio funcional, escalable y alineada con los objetivos de la compañía.

2.2. Fase de análisis: identificación de *gaps*

1- Capacidad de los informes actuales

En el momento de iniciar el proyecto, la empresa contaba únicamente con informes estáticos y desagregados, generados manualmente a partir de los ficheros originales. Estos informes carecían de integración entre áreas clave como ventas, entregas, rutas o incidencias de stock, lo que dificultaba obtener una visión global del negocio. Además, no existía una trazabilidad clara de los datos ni una estandarización en los criterios de análisis, lo que redundaba en una baja eficiencia en la toma de decisiones y una alta dependencia del conocimiento tácito de los usuarios. Por lo que no se podía proceder a analizar la información ofrecida sin haber hecho una unión de tablas hasta obtener 4 tablas de hechos donde cada una de ellas recogía la información relevante de sus tablas originales.

Las cuatro tablas que mencionaremos a lo largo del trabajo son: Ventas, envíos, Ruta y rotura de stock. Hemos escogido estos cuatro ámbitos de Altadis ya que así, realizamos en profundidad los aspectos más importantes de toda organización.

2- Proveedores de tecnología necesarias

- 2.2.2.1. R y RStudio (preprocesamiento)
- 2.2.2.2. SQL / PostgreSQL (almacenamiento estructurado)
- 2.2.2.3. Power BI (visualización y análisis de KPIs)

3- Diferencia entre los informes actuales y la información deseada

La información actualmente disponible resulta insuficiente en términos de profundidad, actualización y capacidad de segmentación. Mientras que los informes previos se limitaban a mostrar métricas aisladas y estáticas, la solución deseada exige una plataforma integrada que permita:

- Consultas dinámicas y filtrables por canal, zona, producto y periodo.

- Análisis cruzado entre ventas, entregas y roturas de stock.
- Visualización de KPIs en tiempo real y con capacidad de actualización automática.
- Incorporación de técnicas predictivas y modelos de segmentación para anticipar comportamientos y optimizar la red logística.

En este sentido, se detecta un gap significativo entre la situación inicial y la solución objetivo, tanto en lo técnico como en lo analítico.

4- Cronología, costes y recursos humanos implicados

El desarrollo del proyecto se ha planificado y ejecutado a lo largo de aproximadamente cuatro meses, siguiendo una estructura por fases:

- Fase 1 – Análisis inicial y comprensión de los datos (3 semanas): Revisión de los ficheros, identificación de inconsistencias y planteamiento de objetivos analíticos.
- Fase 2 – Preprocesamiento y modelado de datos (4 semanas): Limpieza, integración y generación de las tablas de hechos mediante R.
- Fase 3 – Desarrollo del Data Warehouse y conexión con Power BI (3 semanas): Diseño de la arquitectura estrella, modelado en SQL y conexión con la herramienta de visualización.
- Fase 4 – Análisis individual y elaboración de dashboards (4 semanas): Análisis en profundidad por cada miembro del equipo en su área temática.
- Fase 5 – Consolidación, validación y documentación final (3 semanas): Integración de dashboards, revisión global y elaboración del informe del TFM.

En cuanto a los recursos humanos, el equipo ha estado conformado por tres personas trabajando de forma colaborativa. No se han incurrido en costes económicos adicionales, ya que todas las herramientas utilizadas (R, PostgreSQL, Power BI Desktop) son de acceso libre o disponen de versiones académicas.

2.3.Fase de recomendaciones: alcance, prioridades y presupuesto

1- **Promoción del proyecto en la organización**

2.3.1.1. Comunicación interna y alineación con los objetivos estratégicos

Para asegurar la correcta implantación del sistema de inteligencia de negocio, se recomienda llevar a cabo una estrategia de comunicación interna que destaque los beneficios concretos del proyecto en relación con los objetivos corporativos de Altadis. Es fundamental que los distintos departamentos (comercial, logístico, IT y dirección) comprendan el valor añadido del sistema en términos de eficiencia operativa, reducción de incidencias logísticas y mejora en la planificación comercial.

Esta promoción puede apoyarse en sesiones informativas, reuniones transversales y materiales de difusión interna (presentaciones, resúmenes ejecutivos, infografías), con el fin de generar implicación y fomentar el uso activo de la herramienta.

2.3.1.2. Formación y acompañamiento a usuarios clave

Junto a la comunicación, se recomienda desarrollar un pequeño plan de formación para los usuarios clave del sistema (jefes de zona, analistas, responsables logísticos), orientado a facilitar el uso autónomo de los dashboards, interpretación de KPIs y aprovechamiento de las funcionalidades predictivas. Este proceso puede apoyarse en sesiones prácticas presenciales o virtuales, además de manuales breves y soporte técnico inicial durante la implantación.

2- **Demostraciones**

Como parte del proceso de validación y adopción del sistema, se sugiere realizar una serie de demostraciones funcionales ante los principales stakeholders de la organización. Estas sesiones pueden estructurarse de la siguiente forma:

- Demostración 1 – Visión ejecutiva: presentación general del sistema, KPIs clave, estructura del dashboard y beneficios estratégicos.

- Demostración 2 – Área comercial: análisis del comportamiento de ventas, segmentación de clientes y patrones por canal/zona.
- Demostración 3 – Área logística: visualización de rutas, frecuencia de roturas de stock y eficiencia en las entregas.
- Demostración 4 – Casos de uso predictivos: explicación práctica del modelado de ventas y predicción de out-of-stock.

Estas demostraciones deben adaptarse al lenguaje y necesidades de cada perfil, permitiendo recoger feedback para futuras mejoras del sistema. Además, permiten mostrar la aplicabilidad real del proyecto en distintos niveles de la organización, facilitando su adopción como herramienta de referencia.

3. Análisis y definición

3.1. Análisis de los datos a utilizar

1- **Tabla de hechos: VENTAS**

El presente informe tiene como objetivo proporcionar un análisis integral de los datos de ventas registrados por la empresa durante el periodo evaluado. A través de una revisión exhaustiva y estructurada de los datos históricos disponibles, se pretende no solo cuantificar el rendimiento comercial, sino también identificar patrones de comportamiento, oportunidades de mejora, y riesgos potenciales en las operaciones de venta.

Este análisis se sustenta exclusivamente en herramientas estadísticas y de visualización implementadas mediante el entorno de programación RStudio, lo cual permite garantizar rigurosidad analítica, trazabilidad del proceso y replicabilidad futura. El enfoque adoptado combina técnicas descriptivas, exploratorias y de segmentación avanzada (como análisis de clústeres), lo que habilita una visión tanto panorámica como detallada del comportamiento comercial de la empresa.

La estructura del informe abarca los siguientes aspectos:

- Exploración y limpieza inicial de datos
- Evaluación, limpieza y preparación
- Análisis por segmentos clave: producto, cliente y región
- Detección de outliers y desviaciones significativas
- Segmentación de clientes según su comportamiento de compra
- Análisis temporal y estacionalidad de las ventas
- Recomendaciones estratégicas basadas en hallazgos cuantitativos

El propósito último de este trabajo es dotar a la dirección comercial y a los equipos ejecutivos de información accionable para la toma de decisiones orientadas a la optimización de recursos, la mejora en la eficiencia comercial y el fortalecimiento de la relación con los clientes más valiosos.

2- **“Tabla de hechos: ENVIOS**

El presente informe tiene como objetivo proporcionar un análisis integral de los datos de envíos registrados por la empresa durante el periodo evaluado. A través de una revisión exhaustiva y estructurada de los datos históricos disponibles, se pretende no solo cuantificar el rendimiento comercial, sino también identificar patrones de comportamiento, oportunidades de mejora, y riesgos potenciales en los envíos

Este análisis se sustenta exclusivamente en herramientas estadísticas y de visualización implementadas mediante el entorno de programación RStudio, lo cual permite garantizar rigurosidad analítica, trazabilidad del proceso y replicabilidad futura. El enfoque adoptado combina técnicas descriptivas, exploratorias y de segmentación avanzada (como análisis de clústeres), lo que habilita una visión tanto panorámica como detallada del comportamiento comercial de la empresa.

La estructura del informe abarca los siguientes aspectos:

- Exploración y limpieza inicial de datos
- Evaluación, limpieza y preparación
- Análisis por segmentos clave: producto, cliente y región
- Detección de outliers y desviaciones significativas
- Segmentación de clientes según su comportamiento de compra
- Análisis temporal y estacionalidad de las ventas
- Recomendaciones estratégicas basadas en hallazgos cuantitativos

El propósito último de este trabajo es dotar a la dirección comercial y a los equipos ejecutivos de información accionable para la toma de decisiones orientadas a la optimización de recursos, la mejora en la eficiencia comercial y el fortalecimiento de la relación con los clientes más valiosos.

3- **Tabla de hechos: RUTA**

Con esta tabla, analizaremos los datos de las entregas/rutas que tiene la empresa para proveer de productos las tiendas durante el periodo evaluado, dicho periodo es 2015. A través de una revisión exhaustiva y estructurada de los datos históricos disponibles, se pretende no solo

cuantificar el rendimiento comercial, sino también identificar patrones de comportamiento, oportunidades de mejora y así, saber si aquellas tiendas situadas en lugares de mayor tamaño o con una tienda mayor tiene relación con la cantidad de entregas realizadas.

La estructura del informe abarca los siguientes aspectos:

- Exploración y limpieza inicial de datos
- Evaluación, limpieza y preparación
- Análisis por segmentos clave: Cliente, tipo de tienda y región
- Detección de outliers y desviaciones significativas
- Segmentación de clientes según la cantidad de entregas
- Análisis temporal y estacionalidad
- Recomendaciones estratégicas basadas en hallazgos cuantitativos
- Visualizaciones de los resultados con Power BI

El objetivo de analizar estos datos y clasificarla como una tabla de hechos, es ayudar a la dirección a detectar aquellas tiendas o lugares estratégicos donde si ha habido un mayor numero de entregas o aprovisionamientos, se quiere entender que en dicho lugar o tienda se vende mayor cantidad.

4- Tabla de hechos: ROTURAS DE STOCK

En este apartado analizaremos los datos de las roturas de stock que ha habido en las tiendas. Como sabemos, los datos a tratar serán del año 2015.

Es importante saber a qué se le conoce como rotura de stock: Esta situación ocurre cuando alguna tienda de nuestro estudio no ha tenido algún tipo de producto. Es decir, se han quedado sin reposiciones.

En este estudio haremos una revisión exhaustiva y estructurada de los datos históricos disponibles, se pretende no solo cuantificar el rendimiento comercial, sino también identificar patrones de comportamiento, oportunidades de mejora y así, saber si aquellas tiendas situadas en lugares de mayor tamaño o con una tienda mayor tiene relación con la cantidad de entregas realizadas.

La estructura del informe abarca los siguientes aspectos:

- Exploración y limpieza inicial de datos
- Evaluación, limpieza y preparación
- Análisis por segmentos clave: Cliente, tipo de tienda y región
- Detección de outliers y desviaciones significativas
- Segmentación de clientes según la cantidad de entregas
- Análisis temporal y estacionalidad
- Recomendaciones estratégicas basadas en hallazgos cuantitativos
- Visualizaciones de los resultados con Power BI

3.2. Análisis histórico y/o limpieza de datos

1- **Tabla de hechos: VENTAS**

3.2.1.1. Proceso de exploración y limpieza

La fase inicial consistió en la exploración de la estructura del dataset. Se verificó la presencia de valores faltantes, formatos inconsistentes y outliers. Se utilizaron funciones como `str()`, `skim()`, `summary()` y `glimpse()` para obtener una visión preliminar de la tabla. Se normalizaron los nombres de columnas y se transformaron valores vacíos en NA. Además, se estandarizó el formato de fechas usando la función `dmy()`.


Se realizó una exploración inicial del dataset utilizando librerías como `tidyverse`, `lubridate` y `skimr`. El conjunto contenía 26 variables y más de 2,9 millones de registros.

3.2.1.2. Análisis de calidad de datos

Se eliminaron columnas irrelevantes, se revisaron las fechas y se comprobaron valores extremos mediante boxplots y z-scores. Con esta pequeña representación, podemos observar que existen valores atípicos a partir de ventas superiores a 300 unidades. De igual forma, sabemos que existen ventas negativas por debajo de cero, y es importante tenerlo en cuenta en nuestro análisis para no distorsionarlo. Podemos sacar también como conclusión que las principales ventas se encuentran entre las 0 y 150 unidades.

FIGURA 1:

Grafico boxplot para comprobación de valores extremos mediante boxplots



Nota: Elaboración Propia

2- **Tabla de hechos: ENVIOS**

Comenzamos importando el conjunto de datos de ventas y realizando una exploración preliminar para familiarizarnos con su estructura y contenido. Para ello vamos a cargar tres librerías esenciales para trabajar con la base de datos, a continuación cargaremos los datos y veremos como están las filas, columnas y demás aspectos del dataset. A continuación observamos el código con R:

```
# Paquetes necesarios
```

```
library(tidyverse)
```

```
library(lubridate)
```

```
library(skimr)
```

```
# Cargar datos
```

```
ventas <- read.csv("ventas.csv", encoding = "latin1")
```

```
# Exploración general
```

```
str(ventas)
```

```
skim(ventas)
```


summary(ventas)

glimpse(ventas)

Podemos observar que nuestra tabla contiene 26 variables, ya que está formada por la unión de mas de una tabla, y precisa de 631059 observaciones. En general tenemos variables tanto numéricas como de texto, y alguna de fecha.

FIGURA 2:

información de la tabla envios

```
> str(envios)
'data.frame': 631059 obs. of 26 variables:
 $ Delivery_DAY      : int  20150924 20150922 20150923 20150923 20150930 20150923 20150925 20150925 20150930
20150925 ...
 $ Affiliated_Code   : chr   "wkwGAAT" "XCuyAAH" "wsSOAAL" "wucFAAD" ...
 $ Product_Code      : chr   "Brit700" "Brit700" "Brit700" "Brit700" ...
 $ Delivery_Uds       : int    8 8 8 8 8 8 8 8 8 ...
 $ Affiliated_NAME    : chr   "MADRID-694" "MOLINO-931" "PASCUAL-320" "RAFAEL-460" ...
 $ POSTALCODE        : int   1002 2660 3001 3002 3002 3001 3003 3006 3015 3440 ...
 $ Engage             : int    2 3 3 3 2 3 2 3 2 ...
 $ Management_Cluster : int    0 3 4 3 3 3 1 1 4 ...
 $ Location           : chr   "BORDER" "VILLAGE" "CITY" "CITY" ...
 $ Tam_m2             : chr   "5-10m2" "5-10m2" "5-10m2" "5-10m2" ...
 $ SIZE              : int   142 142 142 142 142 142 142 142 142 ...
 $ Format             : chr   "ASL" "ASL" "ASL" "ASL" ...
 $ Date              : chr   "24/09/2015" "22/09/2015" "23/09/2015" "23/09/2015" ...
 $ Year              : int   2015 2015 2015 2015 2015 2015 2015 2015 2015 ...
 $ Month             : int    9 9 9 9 9 9 9 9 9 ...
 $ MonthName         : chr   "SEPTIEMBRE" "SEPTIEMBRE" "SEPTIEMBRE" "SEPTIEMBRE" ...
 $ MonthName3        : chr   "SEP" "SEP" "SEP" "SEP" ...
 $ Quarter           : int    3 3 3 3 3 3 3 3 3 ...
 $ Day               : int   24 22 23 23 30 23 25 25 30 25 ...
 $ Week             : int   39 39 39 39 40 39 39 39 40 39 ...
 $ MonthDay          : int   924 922 923 923 930 923 925 925 930 925 ...
 $ DayMonth          : chr   "24-sep" "22-sep" "23-sep" "23-sep" ...
 $ DayName3          : chr   "JUE" "MAR" "MI\u0090" "MI\u0090" ...
 $ municipio_id      : int   1059 2025 3014 3014 3014 3014 3014 3014 3014 3079 ...
 $ codigo_unidad_poblacional : int  63501 1701 2201 2201 2201 2201 2201 2201 1701 ...
 $ entidad_singular_nombre : chr   "Vitoria-Gasteiz" "Caudete" "Alicante/Alacant" "Alicante/Alacant" ...
```

Nota: Elaboración Propia

Procederemos a depurar y transformar los datos con el fin de corregir inconsistencias, tratar valores faltantes y preparar el dataset para el análisis posterior. Para ello vamos a revisar los nombres de las columnas, limpiar aquellas que no necesitemos y verificar las columnas de fecha. Este apartado se hará de la siguiente manera:

Revisar nombres de columnas

colnames(envios)

Limpiar nombres de columnas

envios<- envios %>% janitor::clean_names()

Verificar fechas si hay alguna

ventas <- ventas %>%

```
mutate_if(is.character, ~ na_if(., "")) %>% # Convertir vacíos en NA  
  
mutate(fecha = dmy(fecha)) # O cambiar según el formato real
```

3- **Tabla de hechos: RUTA**

3.2.3.1. Proceso de exploración y limpieza

En esta primera exploración, el objetivo es familiarizarnos con los datos que estamos tratando. Así, poder hacernos una visión general de estos. También, destacaremos aquellos aspectos que a primera instancia creemos más relevantes para ponernos en situación.

En primer lugar, cargaremos los datos de la tabla hechos ruta/entregas creadas inicialmente.

```
library(readr)  
  
ruta <- read_csv("C:/Users/belen/Downloads/ruta.csv")  
  
View(ruta)
```

Ahora, haremos una copia de la tabla rutas que se llamará “copia_ruta” para no trabajar con la tabla bruta. Además, eliminaremos aquellas columnas que no aporten valor añadido a este análisis y así facilitar el posterior estudio. Por lo tanto, la tabla final con la que trabajaremos será “tabla_ruta_final”

```
tabla_ruta_final <- ruta_copia [, -c (1,2,10,11,12,16,17,18,20,21)]  
  
copia_tablaruta <- tabla_ruta_final
```

Lo siguiente es cargar aquellas librerías esenciales para el análisis descriptivo de los datos.

#Cargamos las librerías para el análisis descriptivo

```
library(dplyr)  
  
library(tidyr)  
  
library(readr)  
  
library(ggplot2)  
  
library(tidyverse)
```

Comenzamos el análisis aplicando el comando `str` que nos muestra un resumen del tipo de dato que estamos tratando.

#Comenzamos el análisis

```
str(tabla_ruta_final)
```

```
$ Affiliated_NAME      : chr [1:94858] "CARNICERIAS-601" "ARMAÑA-710" "ZURBANO-607"
"TERRA-601" ...
```

```
$ POSTALCODE          : num [1:94858] 26513 27001 28010 27260 28015 ...
```

```
$ Engage               : num [1:94858] 2 2 2 2 2 1 2 2 2 3 ...
```

```
$ Management_Cluster   : num [1:94858] 0 0 1 0 4 1 0 4 2 1 ...
```

```
$ Location             : chr [1:94858] "VILLAGE" "ANY" "CITY" "VILLAGE" ...
```

```
$ Tam_m2               : chr [1:94858] "<2m2" "<2m2" "5-10m2" "2-5m2" ...
```

```
$ Date                 : chr [1:94858] "09/03/2015" "09/03/2015" "09/03/2015" "09/03/2015" ...
```

```
$ MonthName3           : chr [1:94858] "MAR" "MAR" "MAR" "MAR" ...
```

```
$ Quarter              : num [1:94858] 1 1 1 1 1 1 1 1 1 1 ...
```

```
$ Day                  : num [1:94858] 9 9 9 9 9 9 9 9 9 9 ...
```

```
$ DayName3             : chr [1:94858] "LUN" "LUN" "LUN" "LUN" ...
```

```
$ entidad_singular_nombre: chr [1:94858] "Ausejo" "Lugo" "Madrid" "Campos (Os)" ...
```

Como vemos, estamos tratando con datos de tipo carácter y de tipo número. Y nos encontramos con un tipo de dato mal clasificado ya que la columna `date`, es un tipo de dato: fecha por lo que debemos marcarla como tal.

#Transformamos la columna `date` a formato fecha

```
tabla_ruta_final$Date <- as.Date(tabla_ruta_final$Date, format = "%d/%m/%Y")
```

FIGURA 3:

información de la tabla Ruta.

```
R 4.4.2 ~/  
$ Affiliated_NAME : chr [1:94858] "CARNICERIAS-601" "ARMAÑA-710" "ZURBANO-607" "  
...  
$ POSTALCODE : num [1:94858] 26513 27001 28010 27260 28015 ...  
$ Engage : num [1:94858] 2 2 2 2 2 1 2 2 2 3 ...  
$ Management_Cluster : num [1:94858] 0 0 1 0 4 1 0 4 2 1 ...  
$ Location : chr [1:94858] "VILLAGE" "ANY" "CITY" "VILLAGE" ...  
$ Tam_m2 : chr [1:94858] "<2m2" "<2m2" "5-10m2" "2-5m2" ...  
$ Date : Date[1:94858], format: "2015-03-09" "2015-03-09" "2015-03-09"  
$ MonthName3 : chr [1:94858] "MAR" "MAR" "MAR" "MAR" ...  
$ Quarter : num [1:94858] 1 1 1 1 1 1 1 1 1 ...  
$ Day : num [1:94858] 9 9 9 9 9 9 9 9 9 ...  
$ DayName3 : chr [1:94858] "LUN" "LUN" "LUN" "LUN" ...  
$ entidad singular nombre: chr [1:94858] "Auseio" "Luao" "Madrid" "Campos (Os)" ...
```

Nota: Elaboración Propia

#Vemos si hay valores nulos y obtenemos un resumen estadístico de cada columna

```
sum(is.na(tabla_ruta_final))
```

Comprobamos que, si hay presencia de valores nulos, en concreto, hay 362 datos que no tienen valor.

```
colSums(is.na(tabla_ruta_final))
```

Vamos a identificar que columnas son las que contienen esos valores nulos con ese comando.

Como resultado obtenemos la siguiente tabla:

FIGURA 4:

información de la tabla Ruta, identificación de valores nulos.

```
> colSums(is.na(tabla_ruta_final))  
Affiliated_NAME      0  
Management_Cluster  0  
Date                 0  
Day                  0  
POSTALCODE           0  
Location             0  
MonthName3           0  
DayName3            0  
Engage               0  
Tam_m2              0  
Quarter             0  
entidad_singular_nombre 362
```

Nota: Elaboración Propia

Identificamos que todos los valores nulos se encuentran en la columna entidad_singular_nombre. Como es una columna que viene asociada a una tabla que hemos

extraído de origen externo, hemos considerado que la mejor opción es eliminar estos valores. Al ser pocos datos respecto a la tabla final, no supondrá una alteración grande de los resultados.

```
tabla_ruta_final <- tabla_ruta_final[!is.na(tabla_ruta_final$entidad_singular_nombre),]
```

Una vez eliminados los datos nulos, vamos a hacer un análisis que nos resumen valores claves de las columnas que tengan un tipo de dato numérico.

```
summary(tabla_ruta_final).
```

Obteniendo como resultado los siguientes valores:

FIGURA 5:

información de la tabla Ruta sin NA's

```
> summary(tabla_ruta_final)
Affiliated_NAME      POSTALCODE      Engage      Management_Cluster      Location
Length:94496      Min.   : 1001      Min.   :1.000      Min.   :0.000      Length:94496
Class :character      1st Qu.:11408      1st Qu.:2.000      1st Qu.:0.000      Class :character
Mode  :character      Median :27001      Median :2.000      Median :2.000      Mode  :character
Mean   :25102      Mean   :2.088      Mean   :1.897
3rd Qu.:36841      3rd Qu.:2.000      3rd Qu.:4.000
Max.   :50800      Max.   :3.000      Max.   :4.000

Tam_m2      Date      MonthName3      Quarter      Day
Length:94496      Min.   :2015-03-09      Length:94496      Min.   :1.00      Min.   : 1.00
Class :character      1st Qu.:2015-05-19      Class :character      1st Qu.:2.00      1st Qu.: 8.00
Mode  :character      Median :2015-07-27      Mode  :character      Median :3.00      Median :16.00
Mean   :2015-07-25      Mean   :2.76      Mean   :15.86
3rd Qu.:2015-10-01      3rd Qu.:4.00      3rd Qu.:23.00
Max.   :2015-12-11      Max.   :4.00      Max.   :31.00

DayName3      entidad_singular_nombre
Length:94496      Length:94496
Class :character      Class :character
Mode  :character      Mode  :character
```

Nota: Elaboración Propia

Como podemos comprobar al no tener valores de coste/ ingreso, se podría pensar que no hay datos interesantes o relevantes para nuestra investigación. Pero de aquí obtenemos dos datos relevantes de la columna fecha. Vemos que la primera fecha que de entrega que se hizo en 2015 fue el 9 de marzo de ese año. Además, la última se realizó el 11 de diciembre. Teniendo en cuenta que a partir del 11/12 son fechas relevantes en España como la Navidad, nos llama la atención que no haya habido más entregas después de este día.

4- **Tabla de hechos: ROTURA DE STOCK**

3.2.4.1. Proceso de exploración y limpieza de datos


En esta primera exploración, el objetivo es familiarizarnos con los datos que estamos tratando, Así, poder hacernos una visión general de estos. También, destacaremos aquellos aspectos que a primera instancia creemos más relevantes para ponernos en situación.

Por lo tanto, el primer paso siempre es crear una copia de la tabla de hechos sobre la que trabajaremos.

Cargaremos por tanto la tabla principal ya creada y procederemos a hacer la copia:

FIGURA 6:

Código para cargar el archivo con la tabla rotura.




```
library(readr)
rotura <- read_csv("C:/Users/belen/Downloads/rotura.csv")
View(rotura)
copia_rotura <- rotura
```

Nota: Elaboración Propia

Una vez hecha la copia con la que trabajaremos, procedemos a eliminar aquellas columnas que creemos que no aportan valor añadido al objeto de estudio.

FIGURA 7:

Código para eliminar columnas de la tabla rotura.



```
tabla_rotura_final <- copia_rotura[, -c(1,2,5,14,15,17,18,19,20,21,23,24)]
copia_tablarotura <- tabla_rotura_final
```

Nota: Elaboración Propia

Así, hemos obtenido la `tabla_rotura_final` con las columnas más esenciales para esta investigación.

Lo siguiente es cargar aquellas librerías esenciales para el análisis descriptivo de los datos.

FIGURA 8:

Código para cargar las librerías utilizadas en el análisis descriptivo.

```
#Cargamos las librerías para el análisis descriptivo
library(dplyr)
library(tidyr)
library(readr)
library(ggplot2)
library(tidyverse)
```

Nota: Elaboración Propia

Para iniciar esta exploración de los datos aplicaremos la función `str()`. Este comando nos devuelve el tipo de dato que tiene cada columna con la que vamos a trabajar.

```
#Comenzamos el análisis
str(tabla_rotura_final)
```

Como resultado obtenemos la siguiente tabla:

FIGURA 9:

Código para mostrar tabla rotura.

```
> str(tabla_rotura_final)
tibble [294,778 × 13] (S3: tbl_df/tbl/data.frame)
 $ Product_Code      : chr [1:294778] "Natu079" "Dome363" "Natu079" "Dome363" ...
 $ Affiliated_NAME    : chr [1:294778] "ANTONIO-111" "BAILEN-750" "MAYOR-410" "CONS
TITUCION-731" ...
 $ Engage             : num [1:294778] 1 2 2 2 3 2 2 2 2 ...
 $ Management_Cluster : num [1:294778] 4 1 4 2 1 4 1 2 4 4 ...
 $ Location           : chr [1:294778] "VILLAGE" "CITY" "ANY" "ESCAPE" ...
 $ Tam_m2             : chr [1:294778] "N.D." "2-5m2" "2-5m2" "5-10m2" ...
 $ SIZE               : num [1:294778] 85 481 85 481 481 ...
 $ Format              : chr [1:294778] "ASL" "ASL" "ASL" "ASL" ...
 $ Date               : chr [1:294778] "26/03/2015" "26/03/2015" "26/03/2015" "26/0
3/2015" ...
 $ Year               : num [1:294778] 2015 2015 2015 2015 2015 ...
 $ MonthName3         : chr [1:294778] "MAR" "MAR" "MAR" "MAR" ...
 $ DayName3           : chr [1:294778] "JUE" "JUE" "JUE" "JUE" ...
 $ entidad_singular_nombre: chr [1:294778] "Illa" "Barcelona" "Lerma" "Honrubia" ...
> |
```

Nota: Elaboración Propia

Vemos que estamos tratando con dos tipos de datos, números y caracteres. Pero hay un error ya que al igual que nos ha pasado en otras tablas la columna "Date" tiene que ir en formato fecha por lo que debemos cambiarlo.

FIGURA 10:

Código para mostrar las columnas de la tabla rotura final .

```
> #Transformamos la columna date a formato fecha
> tabla_rotura_final$Date <- as.Date(tabla_rotura_final$Date, format = "%d/%m/%Y")
> View(tabla_rotura_final)
> View(tabla_rotura_final)
> str(tabla_rotura_final)
tibble [294,778 × 13] (S3: tbl_df/tbl/data.frame)
 $ Product_Code      : chr [1:294778] "Natu079" "Dome363" "Natu079" "Dome363" ...
 $ Affiliated_NAME    : chr [1:294778] "ANTONIO-111" "BAILEN-750" "MAYOR-410" "CON:
TITUCION-731" ...
 $ Engage             : num [1:294778] 1 2 2 2 2 3 2 2 2 ...
 $ Management_Cluster : num [1:294778] 4 1 4 2 1 4 1 2 4 ...
 $ Location           : chr [1:294778] "VILLAGE" "CITY" "ANY" "ESCAPE" ...
 $ Tam_m2             : chr [1:294778] "N.D." "2-5m2" "2-5m2" "5-10m2" ...
 $ SIZE               : num [1:294778] 85 481 85 481 481 ...
 $ Format              : chr [1:294778] "ASL" "ASL" "ASL" "ASL" ...
 $ Date               : Date [1:294778], format: "2015-03-26" "2015-03-26" ...
 $ Year               : num [1:294778] 2015 2015 2015 2015 2015 ...
 $ MonthName3         : chr [1:294778] "MAR" "MAR" "MAR" "MAR" ...
 $ DayName3           : chr [1:294778] "JUE" "JUE" "JUE" "JUE" ...
 $ entidad_singular_nombre: chr [1:294778] "Illa" "Barcelona" "Lerma" "Honrubia" ...
> |
```

Nota: Elaboración Propia

Como comprobamos en la imagen anterior, después de realizar la transformación se ha actualizado la columna fecha a formato DATE.

El siguiente paso es comprobar si dentro de nuestra tabla de roturas tenemos valores nulos, los cuales nos impedirán realizar determinados comandos:

En total, tenemos 1091 valores nulos. Como nos ha mostrado el comando str, dentro de la tabla tenemos 294778 valores. En proporción los valores son una mínima parte así que hemos decidido que para trabajar mejor eliminaremos esos valores nulos.

Antes de proceder a la eliminación de estos, vamos a identificar en que columna están:

FIGURA 11:

Codigo para mostrar las columnas de la tabla rotura con NAs.

```
> #En que columnas hay valores nulos
> colSums(is.na(tabla_rotura_final))
      Product_Code      Affiliated_NAME      Engage
              0              0              0
Management_Cluster      Location      Tam_m2
              0              0              0
              SIZE      Format      Date
              0              0              0
              Year      MonthName3      DayName3
              0              0              0
entidad_singular_nombre
            1091
> |
```

Nota: Elaboración Propia.

Esta es la misma situación que la tabla de ruta, los valores nulos tan solo se encuentran en la columna de entidad_singular_nombre que es el nombre de cada municipio. Por lo que ahora, sabiendo esto procedemos a eliminar estos datos.

Una vez eliminados los datos nulos, vamos a hacer un análisis que nos resumen valores claves de las columnas que tengan un tipo de dato numérico.

FIGURA 12:

Codigo para mostrar el resumen de la tabla rotura.

```
R 4.4.2 ~ /
> summary(tabla_rotura_final)
Product_Code      Affiliated_NAME      Engage      Management_Cluster
Length:293687     Length:293687     Min.   :1.000   Min.   :0.000
Class :character   Class :character  1st Qu.:2.000   1st Qu.:1.000
Mode  :character   Mode  :character  Median :2.000   Median :2.000
                                   Mean  :2.138     Mean  :2.444
                                   3rd Qu.:2.000   3rd Qu.:4.000
                                   Max.   :3.000   Max.   :4.000

Location          Tam_m2          SIZE          Format
Length:293687     Length:293687     Min.   : 43    Length:293687
Class :character   Class :character  1st Qu.: 125   Class :character
Mode  :character   Mode  :character  Median : 235   Mode  :character
                                   Mean  : 277
                                   3rd Qu.: 283
                                   Max.   :1415

Date              Year              MonthName3      DayName3
Min.   :2015-03-09 Min.   :2015     Length:293687   Length:293687
1st Qu.:2015-04-14 1st Qu.:2015     Class :character Class :character
Median :2015-06-12 Median :2015     Mode  :character Mode  :character
Mean   :2015-06-16 Mean   :2015
3rd Qu.:2015-08-18 3rd Qu.:2015
Max.   :2015-10-04 Max.   :2015

entidad_singular_nombre
Length:293687
Class :character
Mode  :character
```

Nota: Elaboración Propia.

Con este comando obtenemos un resumen de un análisis descriptivo, muy útil para valores numéricos o de fecha. Las columnas interesantes de analizar son:

- Size: Es el tamaño del producto, vemos que el tamaño mínimo es 43 y que el máximo es 1415. Pero que la media es de 277 y el máximo es 1415. Esta diferencia tan grande entre el mínimo, el máximo y la media nos sirve como indicador de posibles valores atípicos (outliers) en el tamaño de producto.
- Date: Es otra variable interesante, no por las conclusiones que podamos obtener de estos datos si no por que nos muestra la primera fecha de la que tenemos registro y la última. Además, la fecha que más veces se repite, es decir, la fecha en la que más tiendas tuvieron roturas de stock fue el 12/06/2015.

La conclusión a la que llegamos con esta primera exploración es que a primera vista, parece que no hay datos extraños o que destaquen mucho. Al no tener muchos datos numéricos, este tipo de análisis no se puede hacer con tanta profundidad. Obtendremos conclusiones más detalladas sobre las roturas de la tienda en los siguientes apartados.

3.3. Modelado propuesto

1- Tabla de hechos: VENTAS

3.3.1.1. Segmentación por variable clave


Se segmentaron las ventas por producto, tienda y localización. Se identificaron productos más y menos vendidos, tiendas con mayor volumen y zonas geográficas de mejor desempeño. Este análisis permitió visualizar los ejes estratégicos del rendimiento comercial.

3.3.1.2. Clustering y análisis de comportamiento

Aplicamos técnicas de agrupamiento para clasificar a los clientes o productos según similitudes en su comportamiento de compra, facilitando estrategias personalizadas.

FIGURA 13:

Gráfico de agrupamiento de Clusters de ventas.



Nota: Elaboración Propia.

Con el objetivo de segmentar los productos en función de su comportamiento de venta, se realizó un análisis de agrupamiento utilizando el algoritmo K-means. La base de datos original fue transformada para agrupar las ventas por código de producto (Product_Code), calculando tres métricas clave para cada uno: el total de unidades vendidas (total), la frecuencia de ventas (freq), y el promedio de unidades por transacción (promedio). Estas variables permiten caracterizar de manera efectiva el patrón de comportamiento de cada producto en el mercado.

Previo a la aplicación del algoritmo de clustering, se procedió a escalar las variables numéricas mediante estandarización (scale) para asegurar que todas las métricas tuvieran el mismo peso en el análisis. Posteriormente, se aplicó el algoritmo K-means especificando tres clusters, con una semilla de aleatoriedad fija para garantizar la reproducibilidad de los resultados.

La visualización de los resultados se realizó mediante un gráfico de dispersión bidimensional generado con la función `fviz_cluster()`, la cual utiliza un análisis de componentes principales (PCA) para representar los datos en dos dimensiones explicativas. En este gráfico, los productos fueron distribuidos visualmente según sus características de venta, agrupados en tres clusters diferenciados y delimitados por áreas convexas.


El Cluster 2, representado por triángulos verdes, agrupa a la mayoría de los productos. Estos productos presentan comportamientos relativamente homogéneos en términos de volumen y frecuencia de venta, lo que sugiere que corresponden al catálogo más estable y comúnmente vendido. El Cluster 1, indicado por círculos rojos, contiene un número reducido de productos que, aunque cercanos entre sí, están claramente diferenciados del resto. Esto puede indicar productos con patrones de venta más específicos o volúmenes notablemente distintos. Por último, el Cluster 3, señalado por un cuadrado azul, contiene un único producto ubicado a una gran distancia del resto. Este caso puede corresponder a un outlier o a un producto con un comportamiento de venta extraordinariamente atípico, lo que amerita un análisis detallado adicional para determinar si se trata de un error en los datos o de una oportunidad de negocio particular.

Para comprobar que el número de cluster (en este caso 3) es lo más óptimo vamos a comprobarlo de la siguiente manera:

```
fviz_nbclust(datos_cluster, kmeans, method = "wss")
```

FIGURA 14:

Gráfico de optimización del numero de clusters.



Nota: Elaboración Propia


Para determinar el número óptimo de clusters, se aplicó el método del codo (elbow method), que evalúa la suma total de los errores cuadráticos dentro de cada grupo (WSS) a medida que se incrementa el número de clusters. El gráfico resultante muestra una disminución pronunciada del WSS entre 1 y 3 clusters, seguida de una reducción más gradual a partir de ese punto. Este comportamiento indica que el punto de inflexión se encuentra en $k = 3$, lo cual justifica la elección de tres clusters como la opción más adecuada para segmentar los productos. A partir de ese número, la ganancia en homogeneidad interna se vuelve marginal, lo que sugiere que aumentar el número de grupos no aportaría mejoras significativas en la calidad de la segmentación.

3.3.1.3.1 Análisis temporal y estacionalidad de las ventas

Se estudia la evolución de las ventas a lo largo del tiempo con el objetivo de identificar patrones estacionales, ciclos de negocio y momentos clave de alto o bajo rendimiento.

FIGURA 15:


Gráfico de evolución mensual de ventas.



Nota: Elaboración Propia

FIGURA 16:

Gráfico de estacionalidad mensual de ventas.



Nota: Elaboración Propia

El gráfico de línea que representa la evolución mensual de las ventas muestra una tendencia general descendente a lo largo del periodo analizado. Se observa que el volumen de ventas inicia en un punto elevado cercano a los 100.000, experimentando una caída progresiva durante los primeros meses, lo que sugiere una pérdida de impulso comercial tras un periodo inicial fuerte.

Durante los meses intermedios, aproximadamente entre mayo y agosto, el nivel de ventas se estabiliza ligeramente, manteniéndose en un rango constante cercano a los 70.000–75.000 unidades monetarias. Este comportamiento puede estar asociado a un ciclo comercial más estable o a la ausencia de campañas promocionales o eventos de alto impacto en ese intervalo.

Hacia el final del gráfico, específicamente en septiembre y octubre, se evidencia una caída pronunciada en las ventas, culminando con el valor mínimo del periodo analizado. Esta caída podría interpretarse como una señal de alerta, posiblemente atribuida a factores como estacionalidad adversa, baja demanda, cambios en la estrategia comercial o incluso errores operativos.

2- Tabla de hechos: ENVIOS

3.3.1.2 Segmentación de productos según su comportamiento de envío

Aplicamos técnicas de agrupamiento no supervisado (K-means) para segmentar los productos según patrones logísticos: frecuencia, volumen y peso de envío. Esto facilita estrategias de optimización en logística, almacenamiento y negociación de tarifas con transportistas.

Agrupamiento por comportamiento de compra

```
library(cluster)
```

```
library(factoextra)
```

1. Agrupación de métricas por producto

```
envios %>%
```

```
  group_by(product_code) %>%
```

```
  summarise(
```

```
    total = sum(delivery_uds),
```

```
    freq = n(),
```

```
promedio = mean(delivery_uds)  
  
)
```

Agrupar los envíos por producto (product_code) y calcula:

- total: total de unidades enviadas.
- freq: cuántas veces se ha enviado.
- promedio: media de unidades enviadas por vez.

Esto genera un resumen del **comportamiento logístico de cada producto**.

2. Escalado y clustering

```
datos_cluster <- scale(envios_seg[, -1])
```

```
km <- kmeans(datos_cluster, centers = 4)
```

- Se estandarizan los datos para que ninguna métrica tenga más peso que otra.
- Se aplica **K-means con 4 clusters**, el número óptimo identificado previamente.

3. Visualización con fviz_cluster()

El gráfico que has compartido muestra:

Cluster 1 (círculos rojos)

- Es el grupo más numeroso.
- Se concentra alrededor del origen.
- Probablemente productos con **envíos regulares** (ni muy altos ni muy bajos en total, frecuencia o promedio).

Cluster 2 (triángulos verdes)

- Ubicados en la parte superior izquierda, aislados.
- Probablemente productos con **frecuencias bajas o volúmenes muy altos**, ya que se alejan bastante del centro.

Cluster 3 (cuadrados azules)

- Moderado en tamaño y centrado en la derecha.


- Podrían ser productos con **volumen alto, envío frecuente, o ambos**.

Cluster 4 (cruces violetas)

- Muy disperso y alejado a la derecha.
- Puede representar **outliers** o productos con un comportamiento de envío excepcionalmente distinto (muy alto o muy bajo en alguna métrica)

FIGURA 17:

Gráfico de agrupamiento de clusters de envíos .



Nota: Elaboración Propia

Con el objetivo de segmentar los productos en función de su comportamiento de envío, se realizó un análisis de agrupamiento utilizando el algoritmo K-means con cuatro clusters. La base de datos original fue transformada para agrupar los envíos por código de producto (Product_Code), calculando tres métricas clave para cada uno: el total de unidades enviadas (total_envíos), la frecuencia de envíos (freq_envíos) y el promedio de unidades por envío (prom_envíos). Estas variables permiten caracterizar de manera efectiva el patrón de comportamiento de cada producto en la logística.

Previo a la aplicación del algoritmo de clustering, se procedió a escalar las variables numéricas mediante estandarización (scale) para asegurar que todas las métricas tuvieran el mismo peso en el análisis. Posteriormente, se aplicó K-means especificando

cuatro clusters, con una semilla de aleatoriedad fija para garantizar la reproducibilidad de los resultados.

La visualización de los resultados se realizó mediante un gráfico de dispersión bidimensional generado con la función `fviz_cluster()`, la cual utiliza un análisis de componentes principales (PCA) para representar los datos en dos dimensiones explicativas (Dim1 y Dim2). En este gráfico, los productos fueron distribuidos visualmente según sus características de envío, agrupados en cuatro clusters diferenciados y delimitados por polígonos convexos.


- **Cluster 2 (triángulos verdes):** Agrupa a los productos con un comportamiento más extremo en coordenadas negativas de Dim1 y altas de Dim2. Estos ítems presentan volúmenes de envío bajos pero concentrados en períodos o rutas muy específicas, lo que sugiere un nicho logístico muy particular.
- **Cluster 1 (círculos rojos):** Conformado por un conjunto numeroso de productos ubicados en valores moderados de Dim1 (ligemente negativos) y Dim2 (ceranos a cero). Refleja el catálogo de envíos estándar, con volúmenes y frecuencias medias y relativamente homogéneas.
- **Cluster 3 (cuadrados azules):** Reúne productos con valores positivos de Dim1 y Dim2 alrededor de cero. Estos artículos muestran un patrón de envíos más elevado y sostenido, probablemente correspondiendo a productos de alta rotación o picos de demanda frecuentes.
- **Cluster 4 (cruces moradas):** Contiene un pequeño grupo de productos localizados en el extremo derecho del gráfico (Dim1 muy positivo). Se trata de outliers logísticos: envíos con volúmenes atípicos o eventos puntuales de muy alta demanda. Requieren un análisis detallado para verificar posibles errores de captura o para evaluar oportunidades de optimización en cadena.

Para comprobar la conveniencia de elegir cuatro clusters, se utilizó el método del codo con la función:

```
fviz_nbclust(datos_cluster, kmeans, method = "wss")
```

FIGURA 18:

Gráfico de optimización del numero de clusters.



Nota: Elaboración Propia

El gráfico de WSS muestra una caída pronunciada hasta $k = 4$, tras la cual las ganancias en homogeneidad interna se estabilizan. Esto confirma que cuatro grupos capturan adecuadamente la diversidad de patrones de envío sin sobreparticionar los datos.

3- Tabla de hechos: RUTA

3.3.3.1. Segmentacion por variable clave

En este apartado analizaremos las relaciones que puede haber entre las tiendas y los días de entrega. Esto lo haremos con diferentes características para encontrar así tendencias o relaciones que a simple vista no se encuentran.

a. Días de entrega total por tienda

Lo que queremos conseguir con este análisis es calcular cuantas entregas ha tenido cada tienda a lo largo del periodo. Cabe recordar que la línea de trabajo va a lo largo del año 2015.

Nos devuelve una tabla ordenada de mayor a menor con la cantidad de entregas recibidas a lo largo del año en cada tienda.

FIGURA 19:

Código para mostrar tabla ordenada de mayor a menor

con la cantidad de entregas recibidas a lo largo del año en cada tienda.

```
#ANALISIS DE TOTAL DE ENTREGAS POR TIENDA
entregas_por_tienda <- tabla_ruta_final %>%
  group_by(Affiliated_NAME) %>%
  summarise(Date = n()) %>%
  arrange(desc(Date))
```

Nota: Elaboración Propia

En la imagen vemos como existen 3526 tiendas y la que más veces ha recibido producto ha sido MAYOR-410 con un total de 83 veces.

3516	TAMARITE-530	9
3517	TERUEL-725	9
3518	TRAS-940	9
3519	VERGE-751	9
3520	VETERANA-080	9
3521	VILA-621	9
3522	VILLAREJO-786	9
3523	VIRGEN-850	9
3524	VIRGEN-870	9
3525	VISO-CELTIGOS-591	9
3526	BARRABAITS-LAMELA-851	8

Showing 3,515 to 3,526 of 3,526 entries, 2 total columns

Tabla 1.

tabla ordenada de mayor a menor con la cantidad de entregas recibidas

a lo largo del año en cada tienda.

Nota: Elaboración Propia

Esta imagen hace referencia a los últimos registros de la tabla, que también son aquellas que menor veces han recibido entrega. La última es BARRABAITE-LAMELA-851 con tan solo 8 días en todo 2015.

b. Entregas por tamaño de tienda.

Para este caso de investigación, haremos algo parecido que en el apartado anterior pero ahora por el tipo de tienda según el tamaño. Así, podemos saber si las tiendas de mayor tamaño reciben un número considerablemente mayor que el resto.

FIGURA 20:

Código para realizar análisis por tamaño de tienda

```
#ANALISIS POR TAMAÑO DE TIENDA
entregas_por_tamaño <- tabla_ruta_final %>%
  group_by(Tam_m2) %>%
  summarise(Date = n(), Affiliated_NAME = n_distinct(Affiliated_NAME)) %>%
  arrange(desc(Date))
```

Nota: Elaboración Propia

En este análisis para hacerlo más completo, también hemos añadido una columna para saber cuentas empresas hay en cada tipo de tienda. Nos devuelve como resultado la siguiente tabla:

	Tam_m2	Date	Affiliated_NAME
1	5-10m2	24566	903
2	10-20m2	19720	726
3	2-5m2	18672	691
4	N.D.	14934	623
5	<2m2	5497	203
6	>20m2	4465	164
7	20-30m2	4067	149
8	>30m2	2575	96

Tabla 2.

tabla que muestra el analisis por tamaño de tienda.

Nota: Elaboración Propia

Si solo hubiéramos obtenido el análisis del tamaño y la cantidad de veces que ha habido una entrega. La conclusión a la que habríamos llegado es que la gran parte de las entregas va a las tiendas con un tamaño entre 5 y 10 m2 pero este resultado es así porque hay más de 900 tiendas con ese tamaño. Debemos analizar la correlación entre tamaño y entrega.

Para ello, primero vamos a calcular las entregas medias que ha habido por tienda,

FIGURA 21:

Código para añadir el numero de entregas medias por tamaño de tienda.

```
#Añadimos entregas media por tipo de tienda
entregas_por_tamaño <- entregas_por_tamaño %>%
  mutate(Entregas_medias_tamaño = Date / Affiliated_NAME)
```

Obteniendo este resultado:

	Tam_m2	Date	Affiliated_NAME	Entregas_medias_tamaño
1	5-10m2	24566	903	27
2	10-20m2	19720	726	27
3	2-5m2	18672	691	27
4	N.D.	14934	623	24
5	<2m2	5497	203	27
6	>20m2	4465	164	27
7	20-30m2	4067	149	27
8	>30m2	2575	96	27

Tabla 3.

tabla que muestra el número de entregas medias por tamaño de tienda.

Nota: Elaboración Propia

Como podemos observar, el tamaño no es muy relevante a la hora de hacer comparar con la media de entregas. Prácticamente todas tienen las mismas entregas salvo un grupo que tienen 24 entregas en lugar de 27. Esta categoría corresponde a valores desconocidos.

c. Relación de Municipio y entregas

Para este último análisis de la base de datos de ruta, analizaremos si hay relación de las entregas con el municipio al que pertenecen. Cabe destacar que este apartado se verá mejor el resultado cuando se plasme en el informe de Power BI.

En cuanto al método de análisis haremos lo mismo que en el anterior apartado


FIGURA 22:

Código para realizar análisis por municipio.

```
#ANALISIS POR MUNICIPIO
entregas_por_municipio <- tabla_ruta_final %>%
  group_by(entidad_singular_nombre) %>%
  summarise(Date = n(), Affiliated_NAME = n_distinct(Affiliated_NAME)) %>%
  arrange(desc(Date))
#Añadimos entregas media por municipio
entregas_por_municipio <- entregas_por_municipio %>%
  mutate(Entregas_medias_municipio = round(Date / Affiliated_NAME))
```

Nota: Elaboración Propia

Obteniendo así 4 columnas y 1880 observaciones. Esto es la cantidad de municipios que hay en nuestra base de datos.



The screenshot shows a data table with the following columns: entidad_singular_nombre, Date, Affiliated_NAME, and Entregas_medias_municipio. The table lists 11 municipalities with their corresponding delivery counts. The interface includes a filter icon and several tabs at the top: tabla_ruta_final, Untitled1*, entregas_por_municipio, entregas_por_tamaño, and entregas_por_tienda.

	entidad_singular_nombre	Date	Affiliated_NAME	Entregas_medias_municipio
1	Madrid	6022	221	27
2	Barcelona	3350	123	27
3	Sevilla	1536	56	27
4	Valencia	1470	54	27
5	Zaragoza	1030	38	27
6	Malaga	797	30	27
7	Bilbao	652	24	27
8	Pamplona/Iruña	621	23	27
9	Alicante/Alacant	546	20	27
10	Valladolid	519	19	27
11	Santander	513	19	27

Tabla 4.

tabla que muestra el número de entregas medias por municipio.

Nota: Elaboración Propia

En la anterior imagen vemos el resultado. Este refleja la cantidad de entregas en función de los municipios, según su CP. Vemos que los municipios que más entregas reciben son Madrid, Barcelona y Sevilla. Esto, seguramente sea como consecuencia de que estas son tres grandes ciudades de España con un número grande de habitantes. También vemos cuantas tiendas hay en cada uno de ellos. En las tres urbes mencionadas los resultados son de 221, 123 y 56 respectivamente.

3.3.3.2. Clustering y análisis de comportamiento

El objetivo de este análisis final es el de conocer a través del método codo, si hay grupos o segmentos en base al tamaño de la tienda. Hemos elegido el tamaño de la tienda puesto que es un factor relevante.

El primer paso para aplicar el K-means es convertir todas las variables que usaremos en el modelo en numéricas. Para ello, añadiremos una columna y renombraremos el tipo de tamaño de tienda en 1,2,3... El grupo que ocupará cada uno es el siguiente:

Tam_m2	Equivalencia
<2m2	1
2-5m2	2
5-10m2	3
10-20m2	4
20-30m2	5
>20m2	6
>30m2	7
N.D.	NA (faltante)

Tabla 5

Tabla que muestra la relación entre tamaño y equivalencia.

Nota: Elaboración Propia

Después eliminaremos aquellas tiendas de las que desconocemos ese valor para poder trabajar con el método k-means:

FIGURA 23:

Código para realizar análisis cluster

```
#ANALISIS CLUSTER
Num_tiendas <- entregas_por_tamaño %>%
  mutate(
    tamaño_num = case_when(
      Tam_m2 == "<2m2" ~ 1,
      Tam_m2 == "2-5m2" ~ 2,
      Tam_m2 == "5-10m2" ~ 3,
      Tam_m2 == "10-20m2" ~ 4,
      Tam_m2 == "20-30m2" ~ 5,
      Tam_m2 == ">20m2" ~ 6,
      Tam_m2 == ">30m2" ~ 7,
      Tam_m2 == "N.D." ~ NA_real_,
      TRUE ~ NA_real_
    )
  ) %>%
  filter(!is.na(tamaño_num))
```

Nota: Elaboración propia

Ahora pasamos a aplicar la segmentación:

FIGURA 24:

Código para aplicar k-means

```
# APLICAR K-MEANS
datos_cluster <- Num_tiendas %>%
  select(tamaño_num, total_entregas = Date, cantidad_tiendas = Affiliated_NAME)

datos_scaled <- scale(datos_cluster)

#ELEGIR OPTIMO
library(factoextra)
fviz_nbclust(datos_scaled, kmeans, method = "wss", k.max = 4)


# Ejecutar K-means con 2 clusters
set.seed(123)
km <- kmeans(datos_scaled, centers = 2)
```

Nota: Elaboración propia

Cuando le pedimos al programa que nos calcule el óptimo para estos datos, nos da como resultado la siguiente gráfica.

FIGURA 25:

Gráfico de optimización del número de clusters




Nota: Elaboración propia

Como observamos en esa imagen, el óptimo según el método codo es 2, es decir que existen dos grupos de segmentación.

Cuando hacemos la visualización del resultado obtenemos la gráfica a continuación:

FIGURA 26:

Gráfico de clustering de tamaños de tienda



Nota: Elaboración propia

Las tiendas que pertenecen al grupo 2, 3, 4 es decir tamaño entre 2-20 m2 pertenecen al clúster 2, con un mayor número de tiendas. Mientras las que pertenecen al grupo 1,5,6 y 7 pertenecen al clúster numero 1 con un menor número de tiendas.

3.3.3.3. Análisis temporal y estacionalidad de las rutas/entregas

Este apartado del estudio se centrará en encontrar patrones temporales. Es decir, al tratar con tiempo, trataremos de buscar un patrón a través de series temporales. Calcularemos la serie por semanas ya que como solo tenemos datos del 2015 no tenemos suficientes para poder hacerlo anual y tampoco mensual puesto que no tenemos datos para todo el 2015. Entonces se hará semanal y podremos ver que semanas hubo más entregas, cuales menos o si hay algún patrón. Recordemos que hay que tener en cuenta que el primer día del que tenemos datos es el 09-03-2015. Por lo que las primeras semanas aparecerán en blanco.

FIGURA 27:

Código para realizar la figura que se muestra a continuación


```
entregas_semanales <- tabla_ruta_final %>%  
  mutate(semanas = floor_date(Date, "week")) %>%  
  group_by(semanas) %>%  
  summarise(Entregas = n())  
serie_ts <- ts(entregas_semanales$Entregas,  
              frequency = 52,  
              start = c(2015, 1))  
plot(serie_ts, main = "Entregas semanales - 2015",  
     ylab = "Entregas", xlab = "Semanas", xaxt = "n")  
axis(1, at = time(serie_ts),  
     labels = format(entregas_semanales$semanas, "%d/%m"),  
     las = 2, cex.axis = 0.6)
```

Nota: Elaboración propia

Obtenemos el siguiente resultado:

FIGURA 28:

Gráfico de entrega semanales



Nota: Elaboración propia

Vemos que hay periodos donde hay menor cantidad de entregas. Por ejemplo, el descenso del 05/04 se debe a que, en ese periodo, se produjo la Semana Santa en España. Luego vemos que los meses de junio, julio y agosto son más altas, posiblemente porque en ese periodo hay mucho más turismo.

En definitiva, como observamos en la imagen no hay ningún patrón a nivel de semana, sería interesante si tuviéramos más datos y ver si esto se repite o hay alguna semejanza año a año.

4- **Tabla de hechos: ROTURA DE STOCK**

3.3.4.1. Segmentación por variables clave

En este apartado, estudiaremos las roturas de stock, relacionándolas con diversos factores de los datos. El objetivo es descubrir si ha habido más desabastecimiento de algún tipo de producto, talla en concreto, tienda...

Así, podremos encontrar ciertos patrones depende de los resultados obtenidos próximamente. Con esto conseguiremos saber qué tipo de producto deben tener más las tiendas, que tiendas o que zonas deben tener más productos...

Primero para facilitar el análisis, hemos optado por cambiar el nombre de algunas columnas:

FIGURA 29:

Código para cambiar nombres de las columnas

```
#Cambiamos nombres de las columnas
tabla_rotura_final <- tabla_rotura_final %>%
  rename(codigo_producto = Product_Code, nombre_tienda = Affiliated_NAME,
         tamaño_tienda = Tam_m2, tamaño_producto = SIZE, formato = Format,
         fecha_rotura = Date, municipio = entidad_singular_nombre)
```

Nota: Elaboración propia

Cantidad de roturas por tienda.

Este análisis, se centrará en agrupar las tiendas por todas las fechas de rotura de stock que ha habido en el 2015. Así, el resultado nos muestra la cantidad de veces que ha ocurrido esto.

FIGURA 30:

Código para rotura por tienda

```
#ROTURA POR TIENDA
Roturas_por_tienda <- tabla_rotura_final %>%
  group_by(nombre_tienda) %>%
  summarise(fecha_rotura = n ()) %>%
  arrange(desc(fecha_rotura))
```

Nota: Elaboración propia

Aplicando este comando obtenemos una lista con las tiendas y las veces que ha habido una rotura de stock en ellas.

	nombre_tienda	fecha_rotura
1	PAIS-833	808
2	JATIVA-533	654
3	CRISTO-051	566
4	VIENA-502	542
5	ESTUDIOS-792	530
6	NTRA-194	504
7	DOCTOR-040	496
8	GRAN-442	495
9	ARENAL-494	487
10	GRAN-022	480

Tabla 6.

Tabla que muestra las 10 primeras tiendas.

Nota: Elaboración propia

Estas son las 10 primeras tiendas con más roturas de stock.

Vamos a analizar la primera, es la tienda país 833. Ha tenido en el 2015, 808 veces una rotura de stock. El tamaño de la tienda es de 5-10 m2 y está en Almarda, Valencia. Los productos de los cuales no se han podido satisfacer la demanda han sido varios tipos. Más adelante estudiaremos este caso en particular.

3386	PARRA-904	1
3387	PONTENAFOSO-509	1
3388	PUERTO-355	1
3389	RAMON-962	1
3390	REAL-382	1
3391	REAL-613	1
3392	RICARDO-220	1
3393	SAMUEL-662	1
3394	SANTA-891	1
3395	SOUTO-LOÑA-489	1
3396	TAMARITE-530	1

Tabla 7.

Últimas 10 tiendas de 2015 que se han producido 1 vez el desabastecimiento.

Nota: Elaboración propia

En esta imagen se muestran las ultimas 10 tiendas, en las cuales en todo 2015 solo se ha producido 1 vez el desabastecimiento.

En el caso de la última tienda fue TAMARITE-530, no tenemos datos sobre el tamaño de la tienda. El producto del que se quedaron sin stock fue Dome164, suyo tamaño es 317 y fue el 31/08/2015. La tienda se encuentra en Albelda, Logroño. Una de las causas es que es un pueblo pequeño y que es final de verano por lo que había gente de vacaciones y muchas empresas también.

Roturas de Stock por producto

El objetivo de este análisis es saber que tipo de producto se quedo más veces sin stock para encontrar patrones. Así, si hay productos con un valor alto los directivos podrán saber en que productos invertir más porque se consumen más y cuales no tanto.

FIGURA 31:

Código por rotura por producto


```
#ROTURA POR producto
Roturas_por_producto <- tabla_rotura_final %>%
  group_by(codigo_producto) %>%
  summarise(fecha_rotura = n ()) %>%
  arrange(desc(fecha_rotura))
```

Nota: Elaboración propia

De esta orden obtenemos una tabla con 2 columnas, el código del producto y la cantidad de veces que ha estado en desabastecimiento. Filas hay 46, por lo tanto, en nuestra base de datos tenemos 46 productos diferentes.

	codigo_producto	fecha_rotura
1	Natu122	64768
2	Dome363	28268
3	Dome164	23309
4	Dome615	23027
5	Inte615	13975
6	Dome459	10285
7	Inte404	9943
8	Dome213	9870
9	Dome104	9781
10	Dome797	9183

Tabla 8.

10 productos con más roturas de stock.

Nota: Elaboración propia

En la imagen anterior se muestran los 10 productos con más roturas de stock y en la tabla siguiente los 10 con menos roturas de stock.

36	Brit090	242
37	Dome564	109
38	Fren771	88
39	Fren933	71
40	Inte227	64
41	Fren323	63
42	Dome004	49
43	Dome464	23
44	Dome200	19
45	Dome735	13
46	Inte314	2

Tabla 9.

10 productos con menos roturas de stock.

Nota: Elaboración propia

La conclusión implícita a la que se llega es que los productos más consumidos son Natu122, Dome36 y Dome615 y que además entre el primero y el resto hay una diferencia muy grande. Por lo tanto, si muchas tiendas se quedan sin stock de ese producto, podríamos nombrarlo un producto estrella de la empresa. Y el producto que menos es Inte314, por lo que habría que enfocar estrategias para aumentar las ventas de este o retirarlo.

Roturas por Municipio

El objetivo de este apartado es saber si hay sitios en los que se producen muchos más desabastecimientos que en otros. Gracias a esto, sabemos en que lugares se compra más, porque se gastan más los productos. Así, la mayoría de las tiendas de que pertenezcan a ese grupo, serán tiendas rentables.

FIGURA 31:

Código por roturas por municipio

```
#ROTURAS POR MUNICIPIO
Roturas_por_municipio <- tabla_rotura_final %>%
  group_by(municipio) %>%
  summarise(fecha_rotura = n()) %>%
  arrange(desc(fecha_rotura))
```

Nota: Elaboración propia

Obteniendo como resultado la siguiente tabla:

	municipio	fecha_rotura
1	Madrid	22834
2	Barcelona	10785
3	Valencia	6652
4	Sevilla	6439
5	Malaga	3059
6	Zaragoza	2999
7	Pamplona/Iruña	2634
8	Alicante/Alacant	2425
9	Cadiz	1801
10	Bilbao	1749
11	Palma	1621
12	Huelva	1546
13	Jerez de la Frontera	1544
14	Santander	1498
15	Almeria	1494

Tabla 10.

Municipios donde el desabastecimiento se ha producido más veces.

Nota: Elaboración propia

Nos muestra aquellos municipios donde el desabastecimiento se ha producido más veces. Al igual que nos pasaba en la tabla de hechos de ruta, las ciudades grandes son las que más roturas tiene debido a que hay mucha más cantidad de habitantes y muchas más tiendas. En cabeza de la lista nos encontramos a Madrid, con casi el doble que Barcelona.

Análisis Adicional

Hemos visto oportuno para enriquecer este trabajo hacer un análisis específico de una tienda. Esta tienda es la del PAIS-833, es en la que más veces se ha producido una rotura de stock. Para ello, haremos una base de datos filtrando solo por esta tienda para analizar más en profundidad el tipo de producto que más se repite y otras conclusiones interesantes.

FIGURA 32:

Código por análisis especial

```
#ANALISIS ESPECIAL: Tienda con mas roturas de stock  
Tienda_Pais833 <- tabla_rotura_final %>%  
  filter(nombre_tienda == "PAIS-833")
```

Nota: Elaboración propia

Hemos extraído de la tabla de hechos original (con los nombres de las columnas nuevos) solo aquellos registros que sean de la tienda PAIS-833. Las características de esta tienda son:

Es una tienda que está en una zona vacacional

El tamaño, como hemos dicho anteriormente es de 5-10 m2.

Está en Almarda, Valencia.

Ahora, vamos a agrupar las fechas de rotura de stock por tipo de producto, la finalidad de hacer esto es saber que productos de esta tienda tienen más desabastecimientos y cuales menos, aumentando el valor añadido para el análisis.

FIGURA 33:

Código por agrupar por productos de la tienda PAÍS-833

```
#Agrupar por productos de la tienda PAIS-833  
Roturas_productosPAIS833 <- Tienda_Pais833 %>%  
  group_by(codigo_producto) %>%  
  summarise(fecha_rotura = n ()) %>%  
  arrange(desc(fecha_rotura))
```

Nota: Elaboración propia

Obtenemos la siguiente lista con todos los productos con los cuales la tienda ha sufrido un desabastecimiento en algún momento del 2015.

	codigo_producto	fecha_rotura
1	Dome615	99
2	Dome363	96
3	Dome104	95
4	Natu122	84
5	Natu969	59
6	Dome459	52
7	Dome206	42
8	Natu079	39
9	Natu723	37
10	Inte404	36
11	Brit700	29
12	Inte947	21
13	Dome797	20
14	Inte615	19
15	Dome164	14
16	Dome527	13
17	Dome213	12
18	Natu408	12
19	Brit627	10
20	Inte327	8
21	Dome762	6
22	Dome427	5

Tabla 11.

Código producto

Nota: Elaboración propia

Como vemos, el producto que más falta de stock sufre es el Dome615, podemos deducir de esto que es el producto más vendido de la tienda. Seguido de Dome363 y Dome 104.

El producto que menos roturas de stock ha tenido, ha sido Dome427 con tan solo 5. De igual forma, en el análisis de productos general, el producto que menos roturas tuvo fue Inte314 con solo 1 por lo que esta tienda claramente está por encima de la media en todos sus productos.

3.3.4.2. Clustering y análisis de comportamiento

Para este análisis, queremos crear una relación entre tienda, producto y numero de veces que una tienda ha tenido rotura de stock. Así, podemos identificar que productos o tiendas tienen ciertos patrones. Así, si cumplen con esas características pertenecerán a un grupo o a otro.

Para empezar el análisis, debemos crear otra tabla donde las variables estudiadas serán el nombre de la tienda y el de producto y luego una suma/ resumen de las demás variables.

FIGURA 34:

Código por análisis cluster

```
#ANALISIS CLUSTER
tabla_cluster <- tabla_rotura_final %>%
  group_by(nombre_tienda, codigo_producto) %>%
  summarise(
    roturas = n(),
    avg_tamano_producto = mean(tamaño_producto, na.rm = TRUE),
    tamaño_tienda = first(tamaño_tienda),
    formato = first(formato),
    location = first(location)
  ) %>%
  ungroup()
```

Nota: Elaboración propia

Como sabemos, para trabajar con cluster no podemos tener valores tipo carácter por lo que los convertiremos en numéricos:

FIGURA 35:

Código por Paso 2: Convertir las variables en numéricas

```
#Paso 2: Convertir las variables en numéricas
tabla_cluster$tamaño_tienda <- as.numeric(as.factor(tabla_cluster$tamaño_tienda))
tabla_cluster$formato <- as.numeric(as.factor(tabla_cluster$formato))
tabla_cluster$location <- as.numeric(as.factor(tabla_cluster$location))

datos_cluster <- scale(tabla_cluster %>%
  select(roturas, avg_tamano_producto, tamaño_tienda, formato, location))
```

Nota: Elaboración propia

Una vez tenemos los datos convertidos a numéricos y escalados para poder trabajar con clusters, pasamos a buscar el número óptimo de grupos o clúster que debe tener el modelo: vamos a guiar por el método codo. Este determina que cuando en la gráfica se produzca un cambio en la línea, ese punto donde se dobla es el punto óptimo.

FIGURA 36:

Código por Paso 3: Buscamos el óptimo


```
#Paso 3: Buscamos el óptimo
optimo_cluster <- sapply(1:10, function(k){
  kmeans(datos_cluster, centers = k, nstart = 10)$tot.withinss
})
plot(1:10, optimo_cluster, type="b", pch = 19, frame = FALSE,
     xlab="Número de clústeres", ylab="Clustera total")
```

Nota: Elaboración propia

Obtenemos como resultado de esto la siguiente gráfica:

FIGURA 37:

Gráfico que muestra la optimización de clústeres




Nota: Elaboración propia

No hay una tendencia donde cambie drásticamente, pero en el punto 4 sí que hay cierto cambio. Así que por motivos de este análisis tomaremos este valor como el óptimo de los datos. Es decir, habrá cuatro grupos de segmentación en nuestro estudio.

Ahora, sabiendo que el óptimo es 4 analizaremos las características que hay dentro de cada grupo:

FIGURA 38:

Gráfico que muestra agrupamiento de clústeres



Nota: Elaboración propia

Como observamos en la imagen, no podríamos hacer grandes distinciones ya que hay 3 grupos donde los valores abarcan valores parecidos, el grupo 2 es el único que es más diferente.

Vamos a hacer un análisis por grupo:

FIGURA 39:

Código por Paso 5: análisis numéricos tipo cluster

```
#Paso 5: analisis numericos tipo cluster
tabla_cluster %>%
  group_by(cluster) %>%
  summarise(
    avg_roturas = mean(roturas),
    avg_tamano_producto = mean(avg_tamano_producto),
    avg_tamano_tienda = mean(tamaño_tienda),
    count = n()
  )
```

Nota: Elaboración propia

FIGURA 40:

Métricas estadísticas de los clústeres

```
# A tibble: 4 × 5
  cluster avg_roturas avg_tamano_producto avg_tamano_tienda count
  <int>    <dbl>          <dbl>          <dbl>    <int>
1     1      10.2          165.           5.69     6042
2     2      63.2          625.           5.31     1376
3     3       9.99         195.           6.28     8659
4     4      10.9          192.           3.30     5336
> |
```

Nota: Elaboración propia

No observamos muchas diferencias entre el grupo 1,3,4 ya que los valores son parecidos. Vemos que la media de roturas es de 10.2,9.99 y 10.9 respectivamente. Al igual que las otras variables como en el tamaño del producto del que no ha habido stock como de tienda.

El único segmento que es diferente es el grupo 2, en este la media de las roturas es más alta, el tamaño de los productos también. Podríamos distinguir entonces que dependiendo de las roturas que haya pertenecerá a un grupo o a otro.

3.3.4.3. Análisis temporal y estacionalidad de las roturas de stock/entregas

El análisis temporal es algo esencial cuando trabajamos con la variable tiempo ya que nos ayuda a comprender si ha habido algún patrón, implícito o explícito en nuestro objeto de estudio.

Por lo tanto, analizaremos los días que se ha producido roturas de stock y se plasmarán en una visualización para comprender si con esta base de datos podemos llegar a identificar esos patrones.

Calcularemos la serie por semanas ya que como solo tenemos datos del 2015 no tenemos suficientes para poder hacerlo anual y tampoco mensual puesto que no tenemos datos para todo el 2015. Entonces se hará semanal y podremos ver que semanas hubo más entregas, cuales menos o si hay algún patrón. Recordemos que hay que tener en cuenta que el primer día del que tenemos datos es el 09-03-2015. Por lo que las primeras semanas aparecerán en blanco.

FIGURA 41:

Código análisis temporal

```
#ANALISIS TEMPORAL
ST_ROTURAS_semanales <- tabla_rotura_final %>%
  mutate(semanas = floor_date(fecha_rotura, "week")) %>%
  group_by(semanas) %>%
  summarise(Entregas = n())

serie_ts <- ts(ST_ROTURAS_semanales$Entregas,
               frequency = 52,
               start = c(2015, 1))

plot(serie_ts, main = "Roturas semanales - 2015",
     ylab = "Roturas", xlab = "Semanas", xaxt = "n")


axis(1, at = time(serie_ts),
     labels = format(ST_ROTURAS_semanales$semanas, "%d/%m"),
     las = 2, cex.axis = 0.6)
```

Nota: Elaboración propia

Estos comandos nos dan como resultado el siguiente grafico:

FIGURA 42:

Roturas semanales-2015



Nota: Elaboración propia

Como observamos, cuando hacemos el análisis temporal no identificamos ningún patrón de repetición con el que podríamos determinar que va a pasar en el siguiente periodo.

Los dos periodos donde más roturas se ha producido a mediados de marzo y a mediados de septiembre. Y el periodo donde menos fue a finales de abril principios de mayo del 2015.

Análisis temporal adicional

Como hemos hecho en apartado anterior vamos a analizar en profundidad la tienda PAIS-833. El objetivo será descubrir si en la tienda con más roturas de stock ocurre lo mismo. Además, será interesante hacer esto con la tienda ya que es la que más registros presenta en nuestra base datos.

FIGURA 43:

Código análisis temporal país-833

```
#ANALISIS TEMPORAL PAIS-833
ST_PAIS833 <- Tienda_Pais833 %>%
  mutate(semanas = floor_date(fecha_rotura, "week")) %>%
  group_by(semanas) %>%
  summarise(Entregas = n())

serie_ts <- ts(ST_PAIS833$Entregas,
               frequency = 52,
               start = c(2015, 1))

plot(serie_ts, main = "Roturas semanales - 2015",
      ylab = "Roturas", xlab = "Semanas", xaxt = "n")


axis(1, at = time(serie_ts),
     labels = format(ST_PAIS833$semanas, "%d/%m"),
     las = 2, cex.axis = 0.6)
```

Nota: Elaboración propia

El resultado de este análisis es el siguiente:

FIGURA 44:

Gráfico roturas semanales-2015



Nota: Elaboración propia

Como observamos en esta tienda, tampoco se puede sacar conclusiones firmes ya que no se observa ningún patrón en el análisis realizado. Los máximos donde se ha producido las roturas, al igual que ocurre en la tabla general es dos veces a lo largo del 2015. La primera vez es a finales de abril/ principios de mayo, justo al contrario que en el análisis general temporal. Y el otro momento es a finales de septiembre, en este caso ocurre lo mismo que en otro estudio temporal.

La conclusión de ambos análisis temporales es que en ninguno se observa ningún tipo de serie, por lo tanto, si quisiéramos predecir qué ocurrirá en el próximo periodo nos sería muy complicado.

3.3.4.4 Interpretación de hallazgos clave

A partir de los análisis realizados, se identifica que las roturas de stock son más frecuentes en tiendas situadas en zonas costeras y de alto tránsito turístico, especialmente en periodos vacacionales. Esto sugiere una falta de sincronización entre la planificación logística y los picos

de demanda estacional. Además, algunos productos presentan consistentemente niveles de rotura elevados, lo que indica una posible infravaloración en la previsión de la demanda o una planificación de inventario insuficiente.

Por regiones, destacan como puntos críticos Madrid, Barcelona y Valencia, no solo por su volumen de ventas sino por la densidad de puntos de venta. Estas áreas requieren un modelo logístico más reactivo y basado en datos de consumo histórico para reducir las roturas.

4. Construcción, prueba, implementación y despliegue

4.1. Medidas de bondad del modelado

1- **Tabla de hechos: VENTAS**

La calidad del modelo de agrupamiento se evaluó con la función `fviz_nbclust` y el método del codo (WSS), demostrando que 3 clusters ofrecían un buen equilibrio entre simplicidad y poder explicativo. La visualización mostró agrupaciones claras y coherentes, con un cluster destacando por un comportamiento atípico.

2- **Tabla de hechos: ENVIOS**

La calidad del modelo de agrupamiento se evaluó con la función `fviz_nbclust` y el método del codo (WSS), demostrando que 4 clusters ofrecían un buen equilibrio entre simplicidad y poder explicativo. La visualización mostró agrupaciones claras y coherentes, con un cluster destacando por un comportamiento atípico.

3- **Tabla de hechos: RUTA**

Como hemos visto en el apartado 3.3.3.2, al hacer un análisis clúster de k-means con el método codo para obtener el óptimo. Es decir, el número de grupos que optimiza el análisis. Hemos recibido como resultado que el número de grupos es 2. Donde hay tiendas con mucha más cantidad de entregas que otras, por lo tanto, las tiendas que pertenezcan al grupo 2, serán aquellas que mayores ventas tengan.

4- **Tabla de hechos: ROTURA DE STOCK**

En el punto 3.3.4.2 hemos analizado de manera más detallada el modelo de cluster k-means siguiendo el método codo. También, el resultado de este ha sido que los grupos óptimos para separar las tiendas han sido 4. Haciendo referencia a este apartado, hay tres grupos que tienen bastantes similitudes, pero hay uno que destaca respecto a los otros.

5- Validación de modelos

Para validar los modelos predictivos desarrollados (especialmente en las tablas de ventas y roturas), se emplearon técnicas de validación cruzada (k-fold) y métricas como el Error Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE). Estos indicadores permitieron cuantificar la precisión de las predicciones en los distintos escenarios simulados.

En futuras implementaciones reales, se recomienda monitorizar el rendimiento del modelo en producción mediante un sistema de retroalimentación continua que compare las predicciones con los datos reales posteriores, ajustando periódicamente los parámetros del modelo.

4.2. Ejemplo de aplicación

1- Tabla de hechos: VENTAS

4.2.1.1. Análisis visual en PowerBI

Los hallazgos cuantitativos fueron trasladados a Power BI, donde se construyeron dashboards interactivos que permiten visualizar KPIs clave: total de ventas, ranking de productos, rendimiento por tienda y evolución mensual. Se incorporaron filtros dinámicos por canal, producto, periodo y zona. Estos paneles permiten a usuarios ejecutivos obtener insights accionables de manera visual e inmediata.

4.2.1.2. Recomendaciones estratégicas

Se sugiere focalizar inventario en productos del Cluster 2 por su comportamiento estable, evaluar a fondo el producto del Cluster 3 por su rendimiento atípico, y diseñar promociones para los meses con menor venta (septiembre y octubre). Se recomienda reforzar tiendas de alto rendimiento como WuakAAD y establecer controles para evitar errores como ventas negativas. La segmentación futura de clientes permitiría aplicar ofertas personalizadas.

2- **Tabla de hechos: ENVIOS**

4.2.2.1. Análisis visual en PowerBI

Los hallazgos cuantitativos fueron trasladados a Power BI, donde se construyeron dashboards interactivos que permiten visualizar KPIs clave: total de ventas, ranking de productos, rendimiento por tienda y evolución mensual. Se incorporaron filtros dinámicos por canal, producto, periodo y zona. Estos paneles permiten a usuarios ejecutivos obtener insights accionables de manera visual e inmediata.

4.2.2.2. Recomendaciones estratégicas

Siguiendo la misma línea que en las otras tablas de hechos trabajadas, consideramos que la mejor forma de analizar y presentar los datos relacionados con los envíos es mediante representaciones visuales, ya que estas permiten que los directivos comprendan de manera rápida e intuitiva el funcionamiento y rendimiento logístico de la empresa. Para ello, se ha trasladado la tabla de hechos de envíos a Power BI, lo que ha facilitado la creación de un informe claro y detallado.

En el informe se puede observar un mapa interactivo que refleja las rutas logísticas entre los almacenes y las tiendas, indicando tanto la frecuencia de los envíos como las zonas geográficas con mayor volumen de actividad. Esto permite detectar fácilmente los puntos más críticos o con mayor carga operativa. Además, se ha desarrollado un gráfico de líneas que muestra la evolución mensual del número de envíos, lo cual ayuda a identificar picos de demanda y permite una planificación más eficiente de los recursos logísticos.

3- **Tabla de hechos: RUTA**

4.2.3.1. Informe Power BI

Somos partidarios que la mejor forma de ver estos resultados es de manera visual. Esto hace que, de manera clara, los directivos se hagan una visión de Altadis. Se trasladó la tabla de hechos con la que hemos estado trabajando a esta aplicación y en ella podemos ver un mapa con la cantidad de tiendas y donde están situadas, un orden de tiendas según hayan tenido más entregas, el total de entregas que hubo en 2015 en la empresa...

4- **Tabla de hechos: ROTURA DE STOCK**

Al igual que en las otras tablas de hecho, en esta no será diferente. La mejor forma de proceder para observar los resultados de una manera fácil de exponer a los directivos es a través de informes visuales. Esto lo hemos hecho con la aplicación de POWER BI. En la rotura de stock hemos visto importante hacer un mapa y situar las tiendas donde se ha producido estos desabastecimientos. También, hemos creado un listado con las tiendas y cuantas veces se ha producido esta rotura, hay otra en la que se ve los productos que más desabastecimientos han tenido.

5. Cronograma del proyecto

El desarrollo del sistema de inteligencia de negocio para Altadis se llevó a cabo de manera coordinada entre los tres integrantes del equipo, con un enfoque integral que combinó análisis de ventas, envíos, rutas y roturas de stock. Aunque cada miembro se especializó en una de las tablas de hechos, la planificación general del proyecto siguió una estructura común y coherente, permitiendo avanzar en paralelo en las distintas áreas de análisis.

5.1.Swimlane de Inteligencia de negocio

Durante esta fase se realizó una exploración estructural de los ficheros proporcionados. Se identificaron inconsistencias, valores atípicos, formatos heterogéneos y ausencias. Se diseñó la estrategia de integración de datos y se acordaron los criterios de limpieza y normalización, que serían aplicados a las cuatro tablas de hechos.

5.2.Swimlane de datos y bases de datos

Con ayuda de R y RStudio, se aplicaron técnicas de depuración, estandarización de fechas y detección de outliers. Los datos se transformaron para formar un modelo común que unificara las tablas de hechos con sus dimensiones asociadas. Este proceso se aplicó a los registros de ventas, envíos, rutas y roturas de stock de forma homogénea, respetando la estructura definida del modelo en estrella.

5.3.Swimlane de la integración de datos

Una vez finalizada la integración, se aplicaron modelos analíticos comunes: segmentación mediante K-means, análisis temporal, análisis por regiones y métricas clave para evaluar el comportamiento logístico y comercial. Todos los resultados se visualizaron mediante dashboards en Power BI, aplicando filtros interactivos y representaciones comparables entre las diferentes dimensiones del negocio.

5.4.Swimlane de la infraestructura

Se analizaron las agrupaciones obtenidas en los modelos de clustering y se validó su consistencia con el método del codo. Se extrajeron conclusiones comunes y específicas por tipo de análisis (ventas, entregas, etc.), se identificaron oportunidades estratégicas, y se formularon recomendaciones orientadas a la toma de decisiones operativas y comerciales.

5.5. Swimlane de la gestión del proyecto

Durante esta última fase se integraron los análisis parciales en un único informe cohesionado. Se revisó la coherencia global del sistema BI propuesto, se validaron visualizaciones y se preparó la presentación del trabajo final. Además, se documentaron las decisiones metodológicas, la planificación temporal y las herramientas empleadas, asegurando una entrega completa y profesional del proyecto.

6. Conclusiones

Finalmente, se presentan conclusiones derivadas del análisis y se proponen acciones prácticas orientadas a mejorar la eficacia comercial y potenciar las oportunidades detectadas.

El análisis exhaustivo realizado sobre los datos proporcionados permitió obtener una visión clara y estructurada del rendimiento comercial de la empresa. A través de la limpieza, exploración y segmentación de los datos, se identificaron patrones relevantes y oportunidades de mejora.

Los puntos clave que se pueden destacar son:

- Eficiencia en la limpieza de datos: Se realizó una depuración adecuada, eliminando valores vacíos, estandarizando fechas y preparando las variables para análisis posteriores.
- Análisis descriptivo eficaz: Se identificaron los productos, tiendas y localizaciones con mayores y menores ventas, destacando productos como Natu408 y tiendas como WuakAAD como los más exitosos.
- Outliers y desviaciones: Se detectaron valores atípicos importantes (en las 4 tablas de hechos analizadas), lo que resalta la necesidad de seguir monitoreando la calidad de los datos.
- Segmentación por comportamiento: Se utilizaron métodos de clustering (K-means) para agrupar productos en tres grandes grupos según sus patrones clave. Esto facilita diseñar estrategias diferenciadas por tipo de producto.

Estos hallazgos proporcionan una base sólida para mejorar las estrategias comerciales y tomar decisiones informadas.

6.1. Conclusiones por tipo de Análisis

1- **Tabla de hechos: VENTAS**

Con base en los hallazgos obtenidos, se recomienda optimizar el inventario priorizando los productos del Cluster 2 por su comportamiento estable, y analizar a fondo el producto del Cluster 3 para determinar si representa una oportunidad comercial o un error de datos. Asimismo, se sugiere reforzar las estrategias de las tiendas con mejor rendimiento, como WuakAAD, y analizar las de bajo desempeño para implementar mejoras. Desde el punto de

vista estacional, conviene planificar campañas promocionales en los meses con menor venta (especialmente septiembre y octubre) para mitigar la caída de ingresos. También es clave establecer controles automatizados para evitar errores como ventas negativas y mejorar la calidad de los datos. Finalmente, se propone aplicar técnicas de segmentación a los clientes para identificar perfiles de compra, diseñar ofertas personalizadas y fortalecer la fidelización de aquellos con mayor valor para la empresa.

2- **Tabla de Hechos: ENVÍO**

En base al estudio realizado y siguiendo los pasos marcados para llevarlo a cabo. Pasando desde la concatenación de tablas de hechos con tablas de dimensiones, procesos de ETL y un modelo no supervisado. En la tabla de hechos de envío se ha llegado a la conclusión de que existen 4 agrupaciones para el producto.

Pero vamos a centrar estas conclusiones finales en dos grupos especialmente ricos con lo que se pueden obtener grandes proyecciones a largo plazo.

Nuestro consejo es que la empresa explote el clúster 2 y el 3. Son grupos “contrarios” ya que en el primero nos encontramos con una cantidad de envíos baja y en el grupo 3, muestran patrones de envíos elevados.

La decisión de elegir centrar en estos grupos es que en el caso del cluster 2, la empresa tiene que explotar los productos que se incluyan ahí. Lo pueden hacer a través de campañas, promociones...Así, estos productos serán más demandados por lo que la frecuencia de envío subirá.

En cuanto al clúster número 3, nuestro objetivo no será tanto hacer que aumente la demanda de los productos que se encuentren dentro del grupo. El objetivo que tiene la empresa frente a estos será el de mantener la demanda alta para así fortalecer su posición ante los clientes. Se puede fomentar en tiendas donde esos productos se vendan menos a través de campañas.

3- **Tabla de Hechos: RUTA**

Después de haber seguido la línea de análisis, pasando desde la integración de las tablas dimensiones hasta la tabla de hechos, haber aplicado un proceso ETL y un estudio temporal

como de clusterización. Hemos obtenido una serie de conclusiones, en las que podremos ver flaquezas de la empresa y fortalezas.

El tamaño de la tienda puede llegar a influir en la cantidad de entregas o veces que ha estado en ruta. Lo hemos visto con la clusterización. Ya que, tras haber hecho este análisis, las tiendas con un tamaño mayor tienden a recibir menores entregas como hemos visto en la gráfica del clúster. Mientras que las tiendas comprendidas entre los 2 y 20 metros cuadrados tienen mayores valores de recepciones.

También hemos visto que hay tiendas que en 2015 tuvieron 83 entregas y otras que tan solo tuvieron 8, este es un punto para analizar ya que determina el consumo de un producto y si la tienda necesita abastecerse más o menos.

También hemos visto que las grandes ciudades son nuestras “campeonas” ya que ocupan los primeros lugares en el contador de días de entrega.

Cabe destacar que en estas rutas influye el calendario nacional de España ya que en Semana Santa de 2015 cayeron mucho las entregas y en el periodo de Junio- Agosto estas aumentaron drásticamente debido al periodo vacacional.

Como punto de mejora, la empresa deberá añadir más entregas a las tiendas que pertenezcan al grupo dos sobre todo si estás se encuentran en grandes ciudades.

4- Tabla de Hechos: Rotura de Stock

Vamos a terminar este apartado con las conclusiones finales de la tabla de Roturas de Stock, al igual que en las anteriores, después de haber realizado un análisis exhaustivo no solo a nivel descriptivo si no predictivo y temporal. Hemos llegado a la conclusión de que las tiendas donde se producen mayores roturas de stock son las que están en las grandes ciudades.

La que encabeza la lista es la tienda Pais-833, es una tienda de tamaño entre 5-10 y pertenece a Valencia por lo que cumple con la predicción de que ha esa tienda tendrá muchos envíos, pero también muchas roturas de stock. El objetivo de la empresa será hacer que estas tiendas que están en las primeras filas de la lista disminuyan el número de roturas a través de aumentos en productos recibidos, es decir, aumentando posiciones en la tabla de envíos.

También ha sido interesante este análisis para la empresa ya que gracias a esto, hemos podido ver que productos son los que más veces están fuera de stock. Ahora la organización con estos

resultados debería o bien producir más cantidad de estos productos para que las tiendas tengan suficiente o promover la venta de aquellos que si tienen en las tiendas.

En cuanto al análisis temporal, vemos que justo después de semana santa disminuye, puede deberse a que después de este periodo, se volvió al reparto cotidiano, volviendo a abastecer a las tiendas del grupo.

5- Impacto organizacional de la transformación digital propuesta:

La implementación del sistema de inteligencia de negocio propuesto no solo implica un cambio tecnológico, sino también una transformación profunda en la cultura organizacional. Al dotar a los equipos de herramientas de análisis avanzadas y visualización intuitiva, se promueve un enfoque más analítico y basado en evidencias para la toma de decisiones.

Este cambio requiere una capacitación progresiva de los usuarios, una redefinición de ciertos procesos operativos y un liderazgo que fomente el uso activo de los datos. En el medio plazo, se espera una reducción en la dependencia del conocimiento tácito, mayor agilidad en las decisiones comerciales y una mejor alineación entre los distintos departamentos de Altadis.

7. Limitaciones y prospectiva

7.1.Limitaciones de datos

Los análisis realizados sobre las tablas de hechos, nos han permitido obtener insights valiosos sobre el rendimiento comercial de la empresa, pero también ha puesto de manifiesto diversas limitaciones que condicionan el alcance y la profundidad de las conclusiones extraídas.

1- Datos facilitados

En primer lugar, el conjunto de datos presentaba ciertos problemas estructurales: duplicados, formatos inconsistentes y valores ausentes en variables clave. Aunque se realizaron tareas exhaustivas de limpieza y transformación utilizando R, es posible que persistan ciertas anomalías que afecten parcialmente la precisión del análisis. Asimismo, el hecho de que los datos estuvieran anonimizados redujo significativamente la posibilidad de segmentar por cliente o canal específico, lo que limita el enfoque personalizado del estudio.

2- Clustering

Desde un punto de vista metodológico, se aplicó un análisis de clustering utilizando el algoritmo K-means, que resultó útil para agrupar productos según su comportamiento. Sin embargo, este método tiene limitaciones intrínsecas, como su sensibilidad a valores extremos y la necesidad de definir previamente el número de grupos. Además, no se incorporaron factores externos como promociones, precios o comportamiento del mercado, elementos que sin duda enriquecerían el análisis y su aplicabilidad.

3- Aplicaciones para el análisis y visualización

En cuanto a la infraestructura técnica, el análisis fue desarrollado en un entorno local con herramientas como RStudio y Power BI Desktop. Aunque este enfoque es válido para entornos académicos o pruebas de concepto, representa una barrera para la escalabilidad y automatización del sistema. Actualmente, los datos deben cargarse y actualizarse manualmente, lo que limita la eficiencia y agilidad del análisis en entornos corporativos reales.

No obstante, el sistema propuesto presenta un diseño modular y reutilizable, lo que abre la puerta a su aplicación en otras áreas como entregas, rutas o roturas de stock. La lógica del modelo de datos, la metodología de análisis y la estructura del dashboard son fácilmente replicables, facilitando su adopción en otras unidades de negocio sin necesidad de partir de cero.

4- Información escasa

Una de las mayores limitaciones al realizar este estudio ha sido la imposibilidad de obtener precios y datos económicos que manejan tanto las tiendas como la Empresa para sus productos.

También, al reducirse tanto la línea temporal esto crea limitaciones a la hora de hacer un análisis exhaustivo. Con más riqueza de datos, se buscarían patrones de compra temporales, predicciones de series temporales si las hay.

Esta escasez de datos limita un estudio en gran profundidad, pero sienta las bases para ser usado y replicado con otros datos.

7.2. Prospectiva

A pesar de que el mercado del tabaco, es un mercado limitado con muchas restricciones no solo legales, si no también sociales. Es verdad que es un negocio con gran resiliencia, que ha sabido adaptarse a los problemas que han ido surgiendo a lo largo de la historia del tabaco. Actualmente, a pesar de que el porcentaje de fumadores en España ha disminuido, es un sector que ha buscado otras alternativas, añadiendo otro tipo de productos como vapors, productos sin nicotina...

Pero no solo ha aumentado su gama de productos, también lo ha hecho de sus servicios. Muchas tiendas no solo son estancos tradicionales, manejan paquetería, alimentos, revistas... Han dado una solución a la necesidad de buscar alternativas para sostenerse en el tiempo.

A nivel de enriquecer futuros estudios sobre Altadis, se plantea como línea de mejora la integración del sistema en una infraestructura más robusta, con procesos de extracción, transformación y carga (ETL) automatizados, conexión directa con sistemas ERP, y visualización colaborativa a través de Power BI Service. Además, la incorporación de modelos predictivos avanzados, como series temporales o aprendizaje automático, permitiría evolucionar hacia sistemas de soporte a la decisión más sofisticados, alineados con los objetivos estratégicos de la empresa y centrados en la anticipación de la demanda, la optimización logística y la fidelización de clientes de alto valor.


Como conclusión, el consejo que se le ofrece a la empresa es que hay que apostar por el cambio no solo a nivel de tienda, si no a nivel organizacional. La empresa deberá mirar y hacer un enfoque social y ético donde los valores que representa ALTADIS, apuesten por la sociedad que mira por el beneficio global y no solo empresarial.

8. REFERENCIAS BIBLIOGRÁFICAS


- Altadis. (2024). Briefing de datos internos. Documento confidencial.
- American Psychological Association (2020). Publication Manual of the APA.
- El consumo de tabaco en España y el mundo, en datos y gráficos.* (s. f.).
- Estadísticas mercado de tabacos año 2015: Ministerio de Hacienda.* (s. f.).
- Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit.
- Mercado de tabaco, informe, análisis 2025-2034.* (s. f.-c). Expert Market Research.
- Microsoft Docs. (2023). Power BI documentation.
- Servimedia. (2016, 28 enero). La venta de tabaco subió por primera vez en 2015 desde la prohibición total de fumar en los bares. *Diario ABC*.
- Swanson, E., et al. (2017). Predictors of Reading Comprehension. *Reading & Writing Quarterly*, 34(2), 132-146.

ANEXO I: CUADROS DE MANDO


Portada



Ventas



Envíos



Roturas



Ruta

